BÁO CÁO NGHIÊN CỨU TUẦN 2

LMS TIÊN TIẾN VÀ LEARNING ANALYTICS: PHÂN TÍCH DỮ LIỆU HỌC TẬP VÀ DỰ ĐOÁN NGUY CƠ

Mục tiêu: Thu thập, nạp và kiểm tra chất lượng bộ dữ liệu OULAD

Sinh viên thực hiện: Vũ Hoà Bình
Mã số sinh viên: 202416137
Bộ dữ liệu nghiên cứu: Open University Learning Analytics Dataset (OULAD)
Thời gian hoàn thành: 24 / 10 / 2026

Mục lục

1 Tổng quan tiến độ tuần 2 **2**

2 Thống kê kỹ thuật 7 bảng OULAD **2**

3 Kiểm định chất lượng dữ liệu & Missing Data Audit **3**
3.1 Kết quả kiểm tra giá trị khuyết thiếu 3
3.2 Phân tích bản chất và chiến lược xử lý dữ liệu khuyết thiếu 3

4 Kiểm tra tính toàn vẹn quan hệ **4**
4.1 Kiểm tra liên kết khóa ngoại giữa các bảng 4
4.2 Sơ đồ luồng nạp và kiểm định dữ liệu (Audit Pipeline) 4

5 Phân tích phân bố biến mục tiêu (Target Distribution) **5**
5.1 Phân bố 4 lớp kết quả học tập gốc 5
5.2 Ánh xạ và phân tích bài toán phân loại nhị phân 5
5.3 Giả thuyết về sự phân hóa hành vi giữa Withdrawn và Fail 5

6 Phân tích tương tác tài nguyên học tập theo Khung SEDL **6**
6.1 Tỷ trọng tương tác các loại tài nguyên VLE 6
6.2 Ý nghĩa đối với quá trình trích xuất đặc trưng (Feature Engineering) 6

7 Kế hoạch triển khai tuần 3 **7**

---

1. Tổng quan tiến độ tuần 2

Trong tuần 2, trọng tâm chuyển từ cơ sở lý thuyết sang thực nghiệm dữ liệu thực tế.

STT	Nhiệm vụ nghiên cứu & triển khai	Trạng thái
T2.1	Tải và giải nén hoàn chỉnh 7 file CSV OULAD vào thư mục `data/raw/`	HOÀN THÀNH
T2.2	Xây dựng pipeline nạp dữ liệu bằng Pandas, kiểm tra cấu trúc & kiểu dữ liệu	HOÀN THÀNH
T2.3	Kiểm định giá trị khuyết thiếu (Missing Values Audit) và phân tích nguyên nhân	HOÀN THÀNH
T2.4	Kiểm tra tính toàn vẹn quan hệ (Referential Integrity) qua 4 phép đối chiếu	HOÀN THÀNH
T2.5	Khảo sát phân bố biến mục tiêu (`final_result`) và ánh xạ bài toán nhị phân	HOÀN THÀNH
T2.6	Khảo sát ban đầu tương tác tài nguyên LMS theo Khung lý thuyết SEDL	HOÀN THÀNH

Bảng 1: Bảng tổng kết tiến độ hoàn thành các nhiệm vụ trong Tuần 2

2. Thống kê kỹ thuật 7 bảng OULAD

Dưới đây là bảng tổng hợp các thông số kỹ thuật, số lượng bản ghi, số chiều đặc trưng và mức tiêu thụ bộ nhớ RAM khi nạp vào môi trường phân tích:

Bảng dữ liệu	Số dòng	Số cột	Dung lượng đĩa	RAM nạp	Nội dung nghiệp vụ
`courses.csv`	22	3	0.001 MB	0.00 MB	22 đợt mở lớp (7 module, mở từ 2 đến 4 đợt)
`assessments.csv`	206	6	0.010 MB	0.01 MB	Cấu trúc bài kiểm tra (TMA, CMA, Exam)
`studentInfo.csv`	32,593	12	3.300 MB	4.85 MB	Nhân khẩu học & kết quả cuối kỳ
`studentRegistration.csv`	32,593	5	1.060 MB	1.49 MB	Nhật ký ngày đăng ký và hủy môn
`studentAssessment.csv`	173,912	5	5.430 MB	6.63 MB	Điểm số và ngày nộp bài thực tế
`vle.csv`	6,364	6	0.250 MB	0.38 MB	Danh mục tài nguyên Moodle
`studentVle.csv`	10,655,280	6	432.810 MB	569.05 MB	Log tương tác click chuột theo ngày
Tổng cộng	**10,900,970**	**43**	**442.861 MB**	**582.41 MB**	**Hệ thống 7 bảng liên kết**

Bảng 2: Thống kê kỹ thuật và mức tiêu thụ tài nguyên của 7 bảng dữ liệu OULAD

3. Kiểm định chất lượng dữ liệu & Missing Data Audit

3.1. Kết quả kiểm tra giá trị khuyết thiếu

Bảng dữ liệu	Tổng số ô	Số ô Missing	Tỷ lệ (% ô)	Dòng trùng	Đặc điểm dữ liệu
`courses`	66	0	0.00%	0	Đầy đủ, không khuyết thiếu
`assessments`	1,236	11	0.89%	0	Thiếu ngày thi Exam cuối kỳ
`studentInfo`	391,116	1,111	0.28%	0	Thiếu chỉ số kinh tế vùng IMD
`studentRegistration`	162,965	22,566	13.85%	0	Phần lớn do cấu trúc nghiệp vụ
`studentAssessment`	869,560	173	0.02%	0	Thiếu điểm nộp bài của sinh viên
`vle`	38,184	10,486	27.46%	0	Thiếu tuần bắt đầu/kết thúc
`studentVle`	63,931,680	0	0.00%	787,170*	Trùng khóa (xem chú thích)

Bảng 3: Bảng tổng hợp kiểm định giá trị khuyết thiếu (Missing Values Audit)

Trong bảng `studentVle`, 787,170 bản ghi trùng khóa `(id_student, id_site, date)` nhiều khả năng là các phiên tương tác riêng biệt trong ngày. Cần kiểm tra thêm bản ghi trùng hoàn toàn trên cả 6 cột (`df.duplicated()`) trước khi cộng gộp theo $\sum$`sum_click` để tránh tính đôi.

3.2. Phân tích bản chất và chiến lược xử lý dữ liệu khuyết thiếu

Để đảm bảo tính hợp lệ sư phạm và độ tin cậy của mô hình học máy, các biến khuyết thiếu được phân loại thành 4 nhóm bản chất:

1. **Khuyết thiếu có ý nghĩa cấu trúc nghiệp vụ (Structural Missing) – Cảnh báo rò rỉ dữ liệu**:
    - Cột `studentRegistration.date_unregistration` có **22,521 giá trị khuyết thiếu (69.1% số dòng)**.
    - *Bản chất*: Sinh viên không hủy môn học sẽ không có ngày hủy. Có 10,072 sinh viên có ngày hủy môn và toàn bộ đều có nhãn `final_result == 'Withdrawn'`; 84 sinh viên Withdrawn còn lại không có ngày hủy, có thể do bỏ học ngang mà không làm thủ tục rút. 45 ô thiếu còn lại của bảng thuộc cột `date_registration`, chưa xử lý riêng.
    - *Chiến lược xử lý*: Thông tin hủy môn chỉ được dùng nếu xảy ra trước mốc dự đoán t, không sử dụng thông tin hủy môn sau mốc t để tránh rò rỉ dữ liệu (Data Leakage).
2. **Khuyết thiếu do đặc thù lịch trình thi cử**:
    - Cột `assessments.date` thiếu **11 giá trị (5.3% số dòng)**.
    - *Bản chất*: Toàn bộ 11 bài bị thiếu đều là bài thi kết thúc môn (`assessment_type == 'Exam'`), do ngày thi cuối kỳ không cố định từ đầu khóa.
    - *Chiến lược xử lý*: Gán hạn thi bằng độ dài khóa học `module_presentation_length` lấy từ bảng `courses`.
3. **Khuyết thiếu do chính sách mở của hệ thống LMS**:
    - Hai cột `vle.week_from` và `vle.week_to` thiếu **5,243 giá trị (82.4% số dòng)**.
    - *Bản chất*: Do các tài nguyên học tập (như tài liệu `oucontent`, diễn đàn `forumng`, trang chủ `homepage`) được mở tự do xuyên suốt khóa học cho sinh viên tra cứu, không giới hạn tuần bắt đầu/kết thúc.
    - *Chiến lược xử lý*: Sử dụng loại tài nguyên (`activity_type`) để phân nhóm đặc trưng SEDL.

4. **Khuyết thiếu thông tin cá nhân và điểm số**:

   - Cột `studentInfo.imd_band` thiếu **1,111 giá trị (3.4% số dòng)**: Có thể do sinh viên không cư trú tại vùng điều tra chỉ số nghèo đói của Vương quốc Anh hoặc không kê khai mã bưu chính. Xử lý bằng cách tạo nhóm danh mục riêng: `'Missing'`.
   - Cột `studentAssessment.score` thiếu **173 giá trị (0.1% số dòng)**: Có thể do sinh viên nộp bài nhưng gặp sự cố kỹ thuật hoặc bài thi chưa hoàn tất quy trình chấm. Xử lý bằng cách điền median điểm của chính bài kiểm tra đó, vì điền 0 sẽ ngầm coi sinh viên trượt bài.

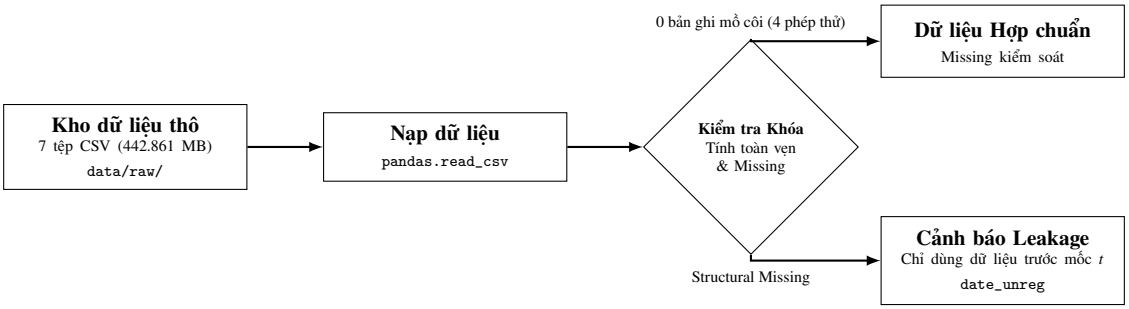
4. Kiểm tra tính toàn vẹn quan hệ

4.1. Kiểm tra liên kết khóa ngoại giữa các bảng

Một hệ thống phân tích học tập đòi hỏi dữ liệu phải có tính nhất quán quan hệ chặt chẽ. Tiến hành kiểm tra đối chiếu tập hợp khóa ngoại:

- **Kiểm tra 1**: Sinh viên trong bảng log tương tác `studentVle` không tồn tại trong bảng thông tin trung tâm `studentInfo`: **0 sinh viên (100% hợp lệ)**.
- **Kiểm tra 2**: Sinh viên có bài nộp trong `studentAssessment` không tồn tại trong `studentInfo`: **0 sinh viên (100% hợp lệ)**.
- **Kiểm tra 3**: Mã bài kiểm tra trong bảng `studentAssessment` không nằm trong danh mục bài thi của `assessments`: **0 bài (100% hợp lệ)**.
- **Kiểm tra 4**: Mã tài nguyên `id_site` trong log tương tác không nằm trong danh mục tài nguyên `vle`: **0 tài nguyên (100% hợp lệ)**.

4.2. Sơ đồ luồng nạp và kiểm định dữ liệu (Audit Pipeline)



5. Phân tích phân bố biến mục tiêu (Target Distribution)

5.1. Phân bố 4 lớp kết quả học tập gốc

Biến mục tiêu `final_result` trong bảng `studentInfo` phản ánh kết quả học tập cuối cùng của 32,593 lượt đăng ký môn học:

Kết quả gốc (`final_result`)	**Số lượng sinh viên**	**Tỷ trọng (%)**	**Ý nghĩa sư phạm trong giáo dục từ xa**
Pass (Đỗ môn học)	12,361	37.9%	Đạt yêu cầu tất cả bài kiểm tra và điểm thi
Withdrawn (Bỏ học giữa chừng)	10,156	31.2%	Rút môn học trước hoặc trong quá trình học
Fail (Trượt môn học)	7,052	21.6%	Hoàn thành khóa học nhưng điểm không đạt chuẩn
Distinction (Đỗ xuất sắc)	3,024	9.3%	Đạt điểm số xuất sắc ở toàn bộ các cấu phần
Tổng số	**32,593**	**100.0%**	**Quy mô toàn bộ bộ dữ liệu OULAD**

Bảng 4: Phân bố chi tiết 4 lớp kết quả học tập gốc trong OULAD

5.2. Ánh xạ và phân tích bài toán phân loại nhị phân

Nhằm phục vụ bài toán can thiệp sớm của cố vấn học tập, 4 lớp gốc được ánh xạ thành bài toán nhị phân chuẩn:

- **Lớp 0 – Not At-Risk (An toàn)**: Gồm `Pass` và `Distinction` với tổng số **15,385 sinh viên (chiếm 47.2%)**.
- **Lớp 1 – At-Risk (Nguy cơ)**: Gồm `Fail` và `Withdrawn` với tổng số **17,208 sinh viên (chiếm 52.8%)**.

5.3. Giả thuyết về sự phân hóa hành vi giữa Withdrawn và Fail

Mặc dù cùng được gán nhãn **At-Risk**, hai phân nhóm này có thể có hành vi khác nhau, đặt ra giả thuyết ban đầu trước khi phân tích chuỗi thời gian:

1. **Nhóm Withdrawn (Bỏ học giữa kỳ - 31.2%)**: Giả thuyết sinh viên ngừng tương tác trên hệ thống LMS từ sớm, dẫn đến khoảng cách ngưng hoạt động (`inactivity_gap`) kéo dài.
2. **Nhóm Fail (Thi trượt - 21.6%)**: Giả thuyết sinh viên vẫn duy trì đăng nhập và click chuột đến cuối kỳ nhưng điểm số bài tập (`score`) thấp và thời gian nộp bài bị trễ hạn thường xuyên (`submit_delay`).

Nếu giả thuyết được xác nhận, việc kết hợp đặc trưng SEDL (Behavioural + Cognitive) có thể hỗ trợ phân loại tốt hơn so với chỉ đếm click đơn thuần.

6. Phân tích tương tác tài nguyên học tập theo Khung SEDL

6.1. Tỷ trọng tương tác các loại tài nguyên VLE

Bảng log `studentVle` ghi nhận tổng cộng **10,655,280 dòng log tương tác** (tương ứng với **39,601,980 lượt click** $\sum$`sum_click`) trên 20 danh mục tài nguyên trực tuyến. Thống kê tỷ lệ phân bổ click cho thấy sự tập trung rõ rệt vào các nhóm tài nguyên chủ lực:

Loại tài nguyên (`activity_type`)	**Tỷ lệ lượt click**	**Chiều tương tác SEDL**	**Vai trò sư phạm trong hệ thống VLE**
`oucontent`	28.30%	Cognitive	Tài liệu bài giảng số hóa chính thống của môn học
`forumng`	20.13%	Social	Diễn đàn trao đổi thảo luận giữa SV và giảng viên
`quiz`	17.63%	Cognitive	Bài tập trắc nghiệm kiểm tra kiến thức
`homepage`	17.55%	Behavioural	Trang chủ môn học, kiểm tra thông báo và lịch trình
`subpage`	8.61%	Cognitive	Trang nội dung phụ và điều hướng cấu trúc bài học
15 loại còn lại (`resource`, `ouwiki`, `url`, ...)	7.78%	Support/Social	Tài liệu đọc thêm, wiki, liên kết ngoài

Bảng 5: Phân bố lượt click theo loại tài nguyên VLE và ánh xạ theo Khung SEDL

Ghi chú: Tỷ lệ phần trăm được tính dựa trên tổng số lượt click thực tế ($\sum$`sum_click`) của 10,655,280 dòng log tương tác trong bảng `studentVle`.

6.2. Ý nghĩa đối với quá trình trích xuất đặc trưng (Feature Engineering)

Kết quả phân tích tương tác tài nguyên cho thấy sự tương thích bước đầu của OULAD với Khung lý thuyết SEDL (Bergdahl et al., 2024):

- Tài nguyên học tập (`oucontent` và `subpage`) chiếm khoảng 36.9% tổng số click (`subpage` được giả định xếp vào Cognitive), phản ánh tương tác với học liệu (*Cognitive Engagement*).
- Diễn đàn trao đổi chiếm hơn **20%** tổng số tương tác, cung cấp dữ liệu để đo lường mức độ tham gia cộng đồng (*Social Engagement*), dù số click diễn đàn chỉ phản ánh tần suất truy cập.
- Tỷ lệ click quiz chiếm 17.6% trên toàn hệ thống; đặc trưng sẽ được tính theo từng sinh viên (tỷ lệ click quiz trên tổng click của sinh viên đó) và là chỉ báo gián tiếp cho tự điều chỉnh học tập (*self-regulated learning*).

7. Kế hoạch triển khai tuần 3

Bước sang tuần 3, đề tài sẽ tiến hành khai phá dữ liệu học tập (Exploratory Data Analysis - EDA) để trả lời định lượng cho các Giả thuyết H1a, H1b, H1c trong Câu hỏi nghiên cứu RQ1:

STT	Nội dung công việc tuần 3
T3.1	Phân tích phân bố số lượt click giữa nhóm At-Risk vs Not At-Risk
T3.2	Khảo sát chuỗi thời gian: Xu hướng click theo tuần học (Temporal Trends), tách riêng Withdrawn và Fail
T3.3	Đánh giá mối quan hệ giữa điểm bài tập đầu tiên (`TMA1`) với kết quả môn
T3.4	Kiểm định thống kê: T-test và ANOVA cho sự khác biệt mức độ tương tác
T3.5	Phân tích ma trận tương quan giữa các nhóm đặc trưng nhân khẩu học và LMS
T3.6	Kiểm tra bản ghi trùng hoàn toàn (`df.duplicated()`) trên `studentVle` và hoàn tất các phép đối chiếu khóa ngoại mở rộng
T3.7	Chạy thử mô hình của bài báo dự đoán cũ (baseline model).

Bảng 6: Kế hoạch phân công nhiệm vụ nghiên cứu trong tuần 3

— HẾT —