ĐỀ TÀI NGHIÊN CỨU

Phân tích dữ liệu học tập và dự đoán sớm kết quả học tập của sinh viên trên nền tảng LMS

BÁO CÁO TIẾN ĐỘ TUẦN 3

RÀ SOÁT VÀ HOÀN THIỆN PHẦN DỮ LIỆU

Khám phá, đánh giá, tiền xử lý và tích hợp dữ liệu OULAD

Bản cập nhật sau góp ý của giảng viên hướng dẫn

Sinh viên thực hiện	Nguyễn Thái Bình
Mã số sinh viên	202416136
Giảng viên hướng dẫn	Nguyễn Thị Thu Giang
Thời gian báo cáo	Tuần 3 – 1/11/2026

Báo cáo trình bày kết quả xử lý dữ liệu, chưa bao gồm huấn luyện và đánh giá mô hình dự đoán.

Mục lục

1 Tổng quan công việc tuần 3 **1**

2 Khám phá và đánh giá dữ liệu OULAD **1**

2.1 Tổng quan bộ dữ liệu OULAD 1

2.1.1 Nội dung và quy mô bảy bảng dữ liệu 1

2.1.2 Khóa và mối quan hệ giữa các bảng 2

2.2 Khám phá đặc điểm dữ liệu 3

2.2.1 Cấu trúc, kiểu dữ liệu và miền giá trị 3

2.2.2 Phân phối biến mục tiêu final_result 3

2.2.3 Phân phối một số đặc trưng nhân khẩu học 4

2.2.4 Phân phối điểm đánh giá học tập 6

2.2.5 Phân phối và xu hướng tương tác học tập VLE 7

2.3 Đánh giá chất lượng dữ liệu 9

2.3.1 Kiểm tra giá trị thiếu 9

2.3.2 Kiểm tra bản ghi trùng lặp 11

2.3.3 Kiểm tra giá trị không hợp lệ và ngoại lai 12

2.3.4 Kiểm tra tính nhất quán và khả năng liên kết 12

2.4 Tổng hợp kết quả và đề xuất tiền xử lý 14

2.4.1 Tổng hợp các vấn đề chất lượng dữ liệu 14

2.4.2 Đề xuất phương án tiền xử lý 16

3 Tiền xử lý và tích hợp dữ liệu OULAD **17**

3.1 Xác định phạm vi và phương án tiền xử lý 17

3.1.1 Xác định dữ liệu đầu vào và biến mục tiêu 17

3.1.2 Xác định phạm vi dữ liệu và các mốc dự đoán 18

3.1.3 Tổng hợp phương án xử lý 19

3.2 Xử lý giá trị thiếu 21

3.2.1 Xử lý giá trị thiếu trong studentInfo 21

3.2.2 Xử lý giá trị thiếu trong studentRegistration 22

3.2.3 Xử lý giá trị thiếu trong studentAssessment, assessments và vle 22

3.2.4 Kiểm tra kết quả xử lý giá trị thiếu 23

3.3 Xử lý dữ liệu trùng lặp, không hợp lệ và ngoại lai 23

3.3.1 Xử lý bản ghi trùng lặp 23

3.3.2 Xử lý giá trị không hợp lệ 24

3.3.3 Xử lý giá trị ngoại lai 24

3.4 Chuẩn hóa cấu trúc và định dạng dữ liệu 25

3.4.1 Chuẩn hóa kiểu dữ liệu 25
3.4.2 Chuẩn hóa giá trị của các thuộc tính 25
3.4.3 Xử lý các thuộc tính thời gian 25
3.5 Tích hợp dữ liệu và xây dựng tập dữ liệu tổng hợp 26
3.5.1 Tích hợp thông tin sinh viên, đăng ký và học phần 26
3.5.2 Tích hợp dữ liệu kết quả đánh giá theo các mốc dự đoán 26
3.5.3 Tích hợp dữ liệu tương tác VLE theo các mốc dự đoán 27
3.5.4 Xác định bộ đặc trưng ban đầu và hợp nhất dữ liệu 28
3.5.5 Kiểm tra kết quả tích hợp 28
3.6 Kiểm tra và đánh giá dữ liệu sau tiền xử lý 30
3.6.1 Đánh giá chất lượng dữ liệu sau xử lý 30
3.6.2 So sánh dữ liệu trước và sau tiền xử lý 30
3.6.3 Khảo sát các đặc trưng tổng hợp sau tiền xử lý 31
3.6.4 Lưu dữ liệu sau tiền xử lý theo từng mốc dự đoán 32

Kết luận tiến độ và kế hoạch tuần tiếp theo **33**

Tài liệu tham khảo **34**

A Cấu trúc và miền quan sát của bảy bảng dữ liệu **34**

B Chi tiết chuyển đổi kiểu dữ liệu **37**

C Danh mục và ý nghĩa 23 đặc trưng ứng viên **39**

D Quy tắc kiểm tra miền và ngoại lệ theo đợt học **40**

Phần 1. Tổng quan công việc tuần 3

Kế thừa bản thử nghiệm của tuần 2, tuần 3 tập trung rà soát sâu dữ liệu nguồn, làm rõ quy tắc xử lý và xây dựng lại tập đặc trưng theo các mốc cảnh báo sớm.

Bảng 1: Các nhóm công việc đã hoàn thành trong tuần 3

STT	Hạng mục công việc	Kết quả chính
1	Rà soát cấu trúc và liên kết của bảy bảng OULAD	Đối chiếu quy mô, khóa và quan hệ giữa các bảng; làm rõ đơn vị sinh viên và lượt học.
2	Khảo sát chi tiết đặc điểm và phân phối dữ liệu	Phân tích theo loại biến; bổ sung bảng và hình về nhãn `final_result`, nhân khẩu học, điểm và tương tác VLE.
3	Kiểm tra lại chất lượng dữ liệu và quy tắc xử lý	Định lượng giá trị thiếu, trùng, ngoại lai, miền hợp lệ và khả năng ghép bảng; ghi nhận cách xử lý có căn cứ.
4	Rà soát lại mốc cảnh báo và hoàn thiện tiền xử lý nguồn	Thay phương án thử nghiệm bằng năm mốc tuần 4, 8, 12, 16 và 24; kiểm chứng cách xử lý thiếu và chuẩn hóa dữ liệu.
5	Tái xây dựng dữ liệu tích hợp và đặc trưng theo mốc	Tổng hợp thông tin nền, bài nộp và VLE trong giới hạn thời gian; xây dựng 23 đặc trưng ứng viên cho mỗi tập.
6	Kiểm chứng và bàn giao dữ liệu sau tiền xử lý	Rà soát tính toàn vẹn khóa, dữ liệu tương lai và chất lượng đặc trưng; xuất các tập dữ liệu mới phục vụ giai đoạn mô hình hóa.

Phần 2. Khám phá và đánh giá dữ liệu OULAD

Khảo sát được thực hiện trên dữ liệu OULAD nguyên trạng nhằm xác định cấu trúc, phân phối và chất lượng trước tiền xử lý. Các thống kê được tính theo đơn vị quan sát của từng bảng; riêng bảng nhật ký tương tác `studentVle` được xử lý theo khối để bảo đảm khả năng khảo sát toàn bộ dữ liệu.

2.1. Tổng quan bộ dữ liệu OULAD

2.1.1. Nội dung và quy mô bảy bảng dữ liệu

OULAD gồm các bảng thông tin học phần, đợt mở lớp, người học, đăng ký, bài đánh giá và hoạt động học tập trực tuyến [1]. Quy mô và nội dung các bảng được tổng hợp tại Bảng 2. Dữ liệu có **28.785 sinh viên duy nhất**; mỗi sinh viên có thể đóng góp nhiều lượt học do đăng ký các học phần hoặc đợt mở lớp khác nhau.

Bảng 2: Quy mô và vai trò của bảy bảng OULAD

Bảng dữ liệu	Nội dung chính	Số dòng	Số cột	Dung lượng (MiB)
courses	Học phần, đợt mở lớp và thời lượng	22	3	0,00
assessments	Bài đánh giá, hạn nộp và trọng số	206	6	0,01
studentInfo	Thông tin sinh viên và kết quả học tập	32.593	12	3,30
studentRegistration	Ngày đăng ký và ngày rút học phần	32.593	5	1,06
studentAssessment	Ngày nộp bài và điểm đánh giá	173.912	5	5,43
vle	Tài nguyên, loại hoạt động và lịch tuần	6.364	6	0,25
studentVle	Nhật ký tương tác và số lượt nhấp	10.655.280	6	432,81
Tổng	Cộng 7 bảng; có cột trùng tên	10.900.970	43	442,86

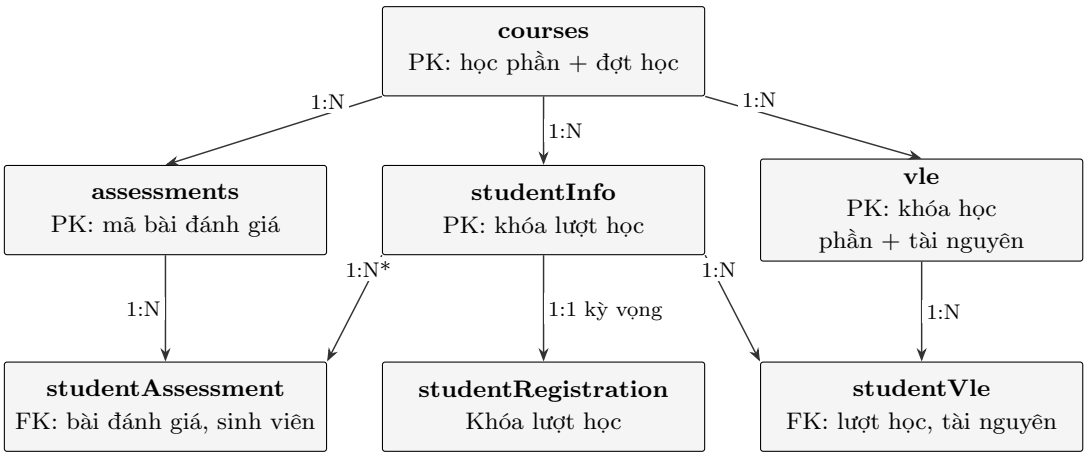
Nhật ký studentVle chiếm tỷ trọng lớn nhất về số bản ghi. Mỗi dòng trong bảng này biểu diễn một sự kiện tương tác, trong khi đơn vị phân tích của bài toán dự đoán là lượt học. Số trường dữ liệu của bảy bảng nguồn không tương đương số đặc trưng đầu vào sau tích hợp.

2.1.2. Khóa và mối quan hệ giữa các bảng

Trong phân tích dự đoán, một lượt học được xác định bởi code_module, code_presentation và id_student. Riêng id_student không đủ vì một sinh viên có thể xuất hiện ở nhiều lượt học. Bảng assessments nối với dữ liệu bài nộp qua id_assessment; danh mục tài nguyên vle được đối chiếu với log bằng đủ khóa học phần, đợt học và id_site.

Bảng 3: Khóa kỳ vọng và quan hệ liên kết giữa bảy bảng

Bảng dữ liệu	Khóa kỳ vọng	Liên kết chính
courses	code_module + code_presentation	Bảng cha của học phần–đợt học
assessments	id_assessment	courses qua code_module + code_presentation
studentInfo	code_module + code_presentation + id_student	courses qua code_module + code_presentation
studentRegistration	code_module + code_presentation + id_student	studentInfo qua khóa lượt học
studentAssessment	id_assessment + id_student	assessments qua id_assessment; lượt học sau khi tra đợt học
vle	code_module + code_presentation + id_site	courses qua code_module + code_presentation
studentVle	Không mặc định khóa chính cho log	studentInfo qua khóa lượt học; vle qua khóa tài nguyên



Hình 1: Sơ đồ khóa và quan hệ liên kết giữa bảy bảng OULAD.

* Bài nộp được đối chiếu với lượt học thông qua thông tin học phần và đợt học của bài đánh giá.

Sáu bảng có khóa kỳ vọng để kiểm tra tính duy nhất. Không áp đặt bộ ba sinh viên–tài nguyên–ngày là khóa duy nhất của `studentVle`, vì có thể có nhiều lần tương tác trong cùng một ngày.

2.2. Khám phá đặc điểm dữ liệu

2.2.1. Cấu trúc, kiểu dữ liệu và miền giá trị

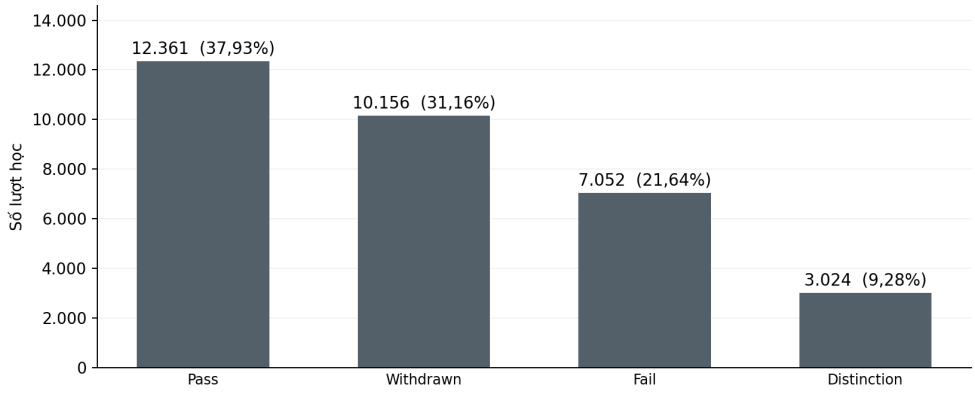
Quá trình khảo sát cấu trúc ghi nhận kiểu dữ liệu, vai trò thuộc tính, số giá trị phân biệt và miền giá trị quan sát của **43 trường dữ liệu** trên bảy bảng. Các trường `id_student`, `id_site` và `id_assessment` được xác định là mã định danh dù được lưu dưới dạng số. Ngược lại, `gender`, `age_band`, `highest_education` và `activity_type` là biến phân loại, được mô tả bằng tần suất và tỷ lệ theo nhóm.

Các biến định lượng có ý nghĩa và đơn vị khác nhau: `score` và `weight` được biểu diễn theo thang 0–100; `sum_click` và `num_of_prev_attempts` là biến đếm; `studied_credits` biểu thị số tín chỉ. Các trường thời gian được tính theo số ngày tương đối với ngày bắt đầu đợt học. Giá trị ngày âm có thể phản ánh sự kiện phát sinh trước ngày 0, vì vậy không được mặc nhiên coi là không hợp lệ.

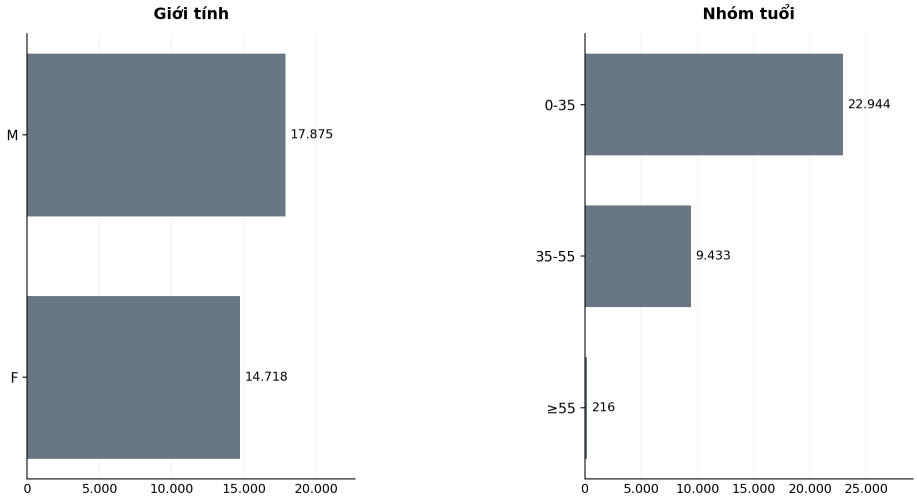
Thông tin cấu trúc và miền quan sát của từng thuộc tính được trình bày tại Phụ lục A. Miền giá trị quan sát chỉ phản ánh dữ liệu hiện có; việc xác định giá trị hợp lệ cần dựa trên quy tắc của từng trường.

2.2.2. Phân phối biến mục tiêu final_result

`final_result` trong `studentInfo` là kết quả cuối kỳ, gồm bốn nhãn *Pass*, *Distinction*, *Fail* và *Withdrawn*. Tỷ lệ được tính trên 32.593 *lượt học*, không phải 28.785 sinh viên duy nhất.



Hình 2: Phân phối bốn lớp kết quả cuối kỳ theo lượt học.



Hình 3: Phân phối giới tính và nhóm tuổi theo lượt học.

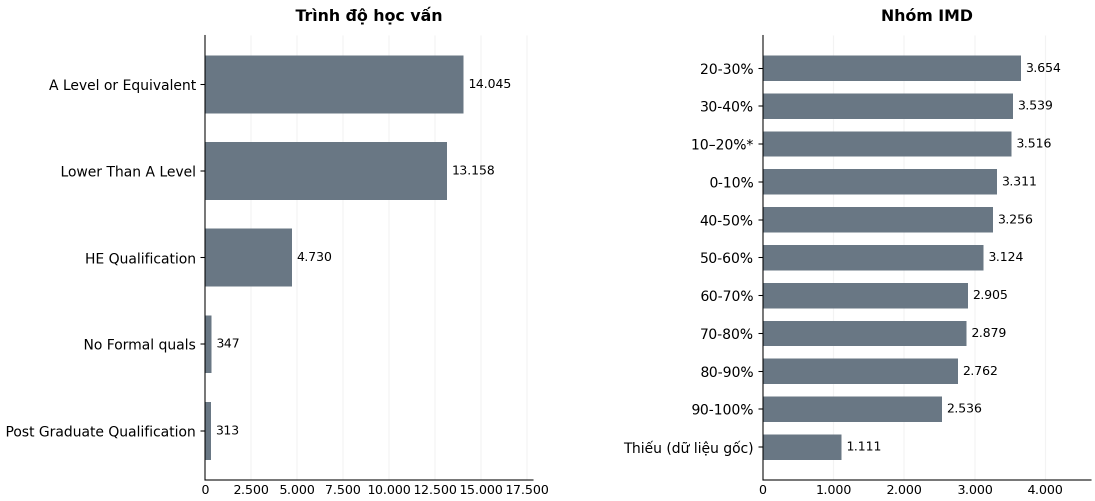
Bảng 4: Phân phối bốn nhãn `final_result`

Kết quả học tập	Số lượt học	Tỷ lệ (%)
Pass	12.361	37,93
Withdrawn	10.156	31,16
Fail	7.052	21,64
Distinction	3.024	9,28

Tần suất các lớp chênh lệch đáng kể (lớp lớn nhất gấp khoảng 4,09 lần lớp nhỏ nhất). Giai đoạn mô hình cần xem xét các chỉ số đánh giá theo lớp; Phần 3 vẫn giữ nguyên bốn nhãn gốc.

2.2.3. Phân phối một số đặc trưng nhân khẩu học

Phân phối nhân khẩu học được thống kê cho sáu thuộc tính: `gender`, `age_band`, `highest_education`, `region`, `imd_band` và `disability`. Hình 3 và Hình 4 minh họa các nhóm tiêu biểu; bảng thống kê kèm theo thể hiện tần suất và tỷ lệ trên toàn bộ lượt học.



Hình 4: Phân phối trình độ học vấn và nhóm IMD theo lượt học.

Bảng 5: Phân phối sáu thuộc tính nhân khẩu học theo lượt học

Cột dữ liệu	Nhóm quan sát	Số lượt học	Tỷ lệ (%)
gender	M	17.875	54,84
gender	F	14.718	45,16
age_band	0-35	22.944	70,40
age_band	35-55	9.433	28,94
age_band	55≤	216	0,66
highest_education	A Level or Equivalent	14.045	43,09
highest_education	Lower Than A Level	13.158	40,37
highest_education	HE Qualification	4.730	14,51
highest_education	No Formal quals	347	1,06
highest_education	Post Graduate Qualification	313	0,96
region	Scotland	3.446	10,57
region	East Anglian Region	3.340	10,25
region	London Region	3.216	9,87
region	South Region	3.092	9,49
region	North Western Region	2.906	8,92
region	West Midlands Region	2.582	7,92
region	South West Region	2.436	7,47
region	East Midlands Region	2.365	7,26
region	South East Region	2.111	6,48
region	Wales	2.086	6,40
region	Yorkshire Region	2.006	6,15
region	North Region	1.823	5,59

Còn tiếp trang sau

Tiếp Bảng 5

Cột dữ liệu	Nhóm quan sát	Số lượt học	Tỷ lệ (%)
region	Ireland	1.184	3,63
imd_band	20-30%	3.654	11,21
imd_band	30-40%	3.539	10,86
imd_band	10-20	3.516	10,79
imd_band	0-10%	3.311	10,16
imd_band	40-50%	3.256	9,99
imd_band	50-60%	3.124	9,58
imd_band	60-70%	2.905	8,91
imd_band	70-80%	2.879	8,83
imd_band	80-90%	2.762	8,47
imd_band	90-100%	2.536	7,78
imd_band	—	1.111	3,41
disability	N	29.429	90,29
disability	Y	3.164	9,71

Ký hiệu * trên biểu đồ IMD chỉ nhóm mang nhãn nguồn `10-20` (thiếu hậu tố %); việc thống nhất cách ghi thành `10-20%` được thực hiện ở Phần 3. Tại bảng phân phối, tỷ lệ nhóm này được tính trên toàn bộ 32.593 lượt học (3.516/32.593 = 10,79%), bao gồm cả những lượt học thiếu thông tin IMD.

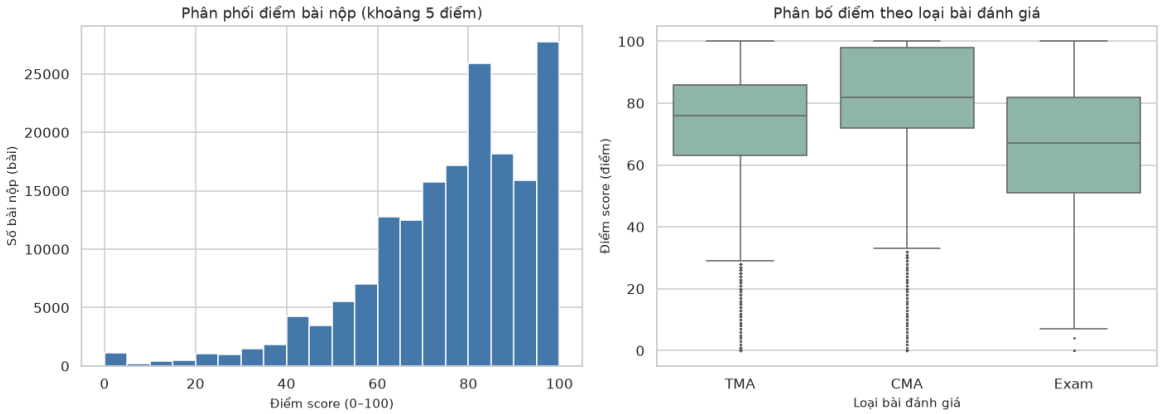
Tỷ trọng các nhóm giới tính, tuổi và học vấn không đồng đều, trong đó nhóm tuổi 0–35 chiếm ưu thế. Do một sinh viên có thể đóng góp nhiều lượt học, phân phối theo lượt học không hoàn toàn đại diện cho phân phối theo cá nhân. Chênh lệch tần suất giữa các nhóm cũng chưa xác lập quan hệ nhân quả với kết quả cuối kỳ. Tình trạng thiếu IMD được phân tích tại mục 2.3.1.

2.2.4. Phân phối điểm đánh giá học tập

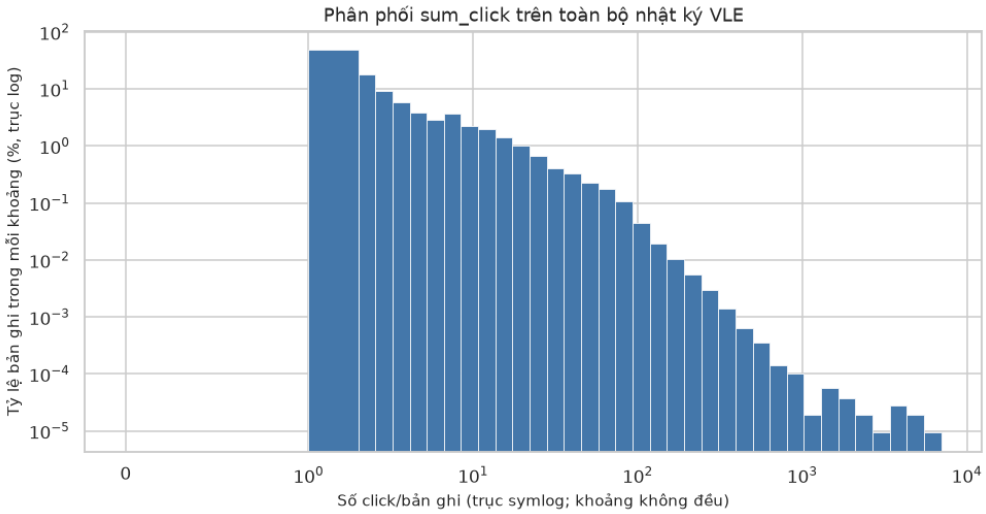
Phân tích điểm được thực hiện ở cấp *bài nộp*. Bảng `studentAssessment` được liên kết với `assessments` theo `id_assessment` để phân biệt TMA, CMA và Exam. Trong số các bài nộp có điểm hợp lệ, trung vị đạt **80** và trung bình đạt **75,80**; các điểm thiếu được loại khỏi phép tính thống kê nhưng vẫn được ghi nhận riêng.

Bảng 6: Thống kê điểm theo loại bài đánh giá

Loại bài đánh giá	Số bài nộp	Số bài có điểm	Điểm trung bình	Điểm trung vị	Số giá trị thiếu
CMA	70.527	70.527	81,03	82,00	0
Exam	4.959	4.959	65,57	67,00	0
TMA	98.426	98.253	72,56	76,00	173



Hình 5: Phân phối điểm bài nộp và so sánh theo loại đánh giá.



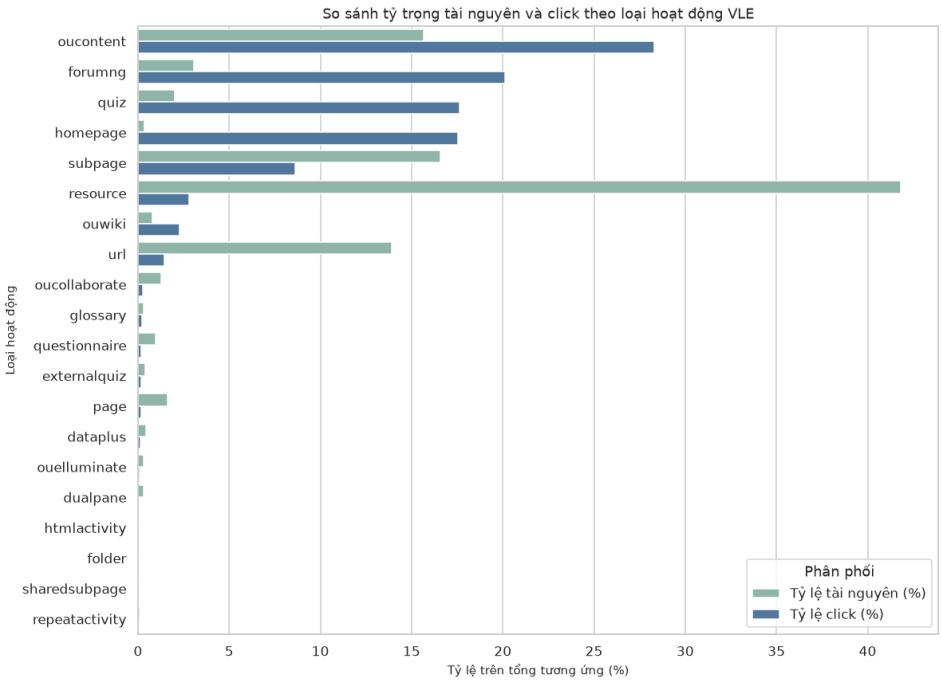
Hình 6: Phân phối số click theo từng bản ghi gốc của nhật ký VLE.

Phân phối điểm khác nhau giữa các loại đánh giá nhưng chưa hiệu chỉnh độ khó hoặc thời điểm. Điểm không được sử dụng trong đặc trưng cảnh báo sớm của Phần 3 vì OULAD không ghi thời điểm công bố kết quả chấm.

2.2.5. Phân phối và xu hướng tương tác học tập VLE

Trên **10.655.280** bản ghi `studentVle`, tổng cộng có **39.605.099 lượt click**. Giá trị `sum_click` có trung vị **2**, trung bình **3,72**, phân vị 99 là **34** và cực đại **6.977** click/bản ghi. Phân phối có đuôi phải dài; số click cao chưa phải bằng chứng dữ liệu sai.

Phân tích theo `activity_type` sử dụng hai đại lượng với mẫu số khác nhau: tỷ lệ tài nguyên trên bảng `vle` và tỷ lệ lượt click trên bảng `studentVle`. Việc phân biệt hai đại lượng giúp đánh giá mức độ sử dụng từng loại học liệu mà không đồng nhất số lượng tài nguyên với cường độ truy cập.

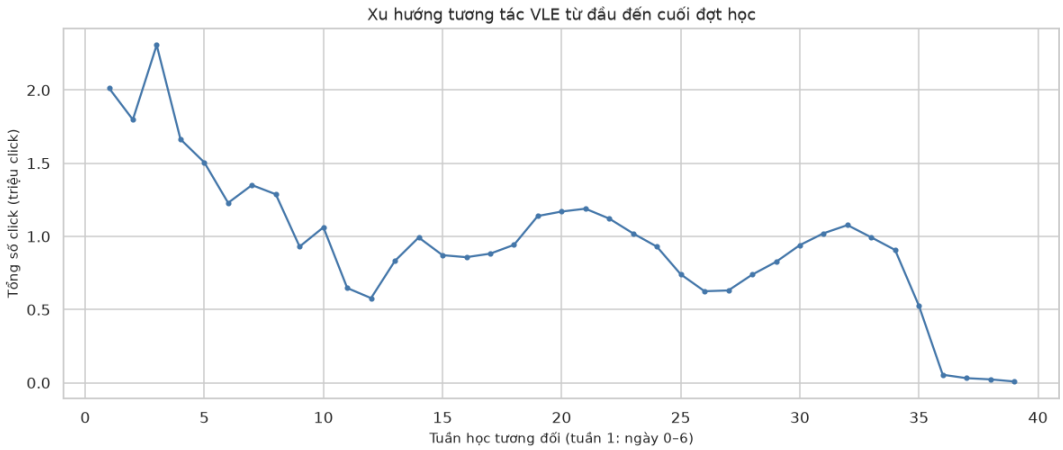


Hình 7: So sánh tỷ trọng tài nguyên và lượt click theo loại hoạt động VLE.

Bảng 7: Tài nguyên và lượt click theo loại hoạt động VLE

Loại hoạt động	Số tài nguyên	Số bản ghi VLE	Tổng số click	Tỷ lệ click (%)
oucontent	996	1.963.782	11.206.803	28,30
forumng	194	2.408.457	7.973.390	20,13
quiz	127	914.573	6.981.240	17,63
homepage	22	1.735.226	6.949.064	17,55
subpage	1.055	1.949.898	3.411.582	8,61
resource	2.660	813.185	1.110.132	2,80
ouwiki	49	178.165	894.512	2,26
url	886	407.716	566.702	1,43
oucollaborate	82	65.793	108.974	0,28
glossary	21	17.435	87.962	0,22
questionnaire	61	44.905	64.764	0,16
externalquiz	26	50.910	64.292	0,16
page	102	47.549	63.631	0,16
dataplus	28	13.506	47.468	0,12
ouelluminate	21	22.360	39.028	0,10
dualpane	20	10.153	20.716	0,05

Còn tiếp trang sau



Hình 8: Tổng số click VLE theo tuần học tương đối, trên dữ liệu thô.

Tiếp Bảng 7

Loại hoạt động	Số tài nguyên	Số bản ghi VLE	Tổng số click	Tỷ lệ click (%)
htmlactivity	4	6.835	9.239	0,02
folder	2	4.678	5.420	0,01
sharedsubpage	3	148	171	0,00
repeatactivity	5	6	9	0,00

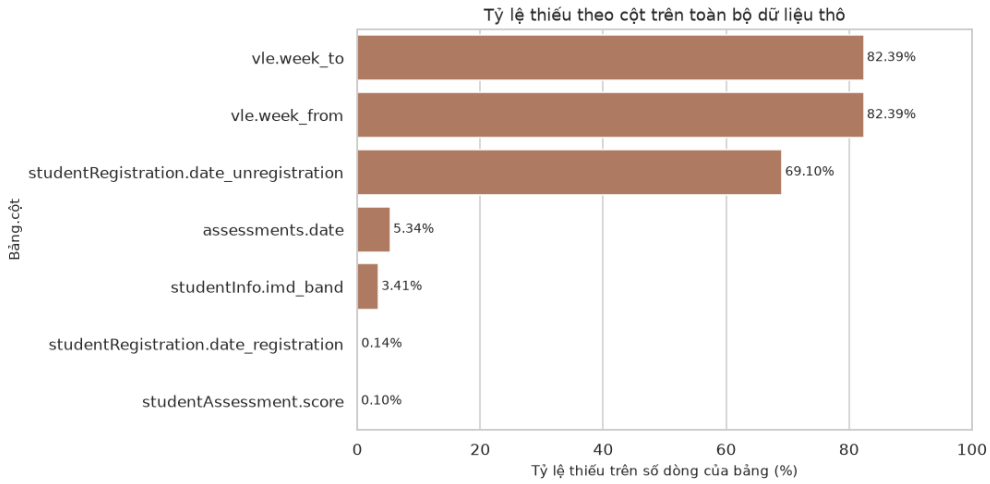
Click tập trung ở một số nhóm tài nguyên, đặc biệt học liệu số và diễn đàn. Số click phản ánh tần suất truy cập chứ không đo trực tiếp chất lượng hiểu bài hoặc kết quả học tập.

Tổng click đạt cực đại ở tuần 3. Đường xu hướng tổng hợp chịu ảnh hưởng của số lượng lượt học còn hoạt động và sự khác biệt về lịch trình giữa các học phần, do đó không phản ánh trực tiếp mức tương tác bình quân của một sinh viên.

2.3. Đánh giá chất lượng dữ liệu

2.3.1. Kiểm tra giá trị thiếu

Kiểm tra tính đầy đủ được thực hiện trên toàn bộ 43 trường dữ liệu. Kết quả ghi nhận **7 thuộc tính có giá trị thiếu** với tổng cộng **34.347 ô thiếu**. Số ô thiếu không tương đương số bản ghi thiếu, do một bản ghi có thể thiếu đồng thời nhiều thuộc tính.



Hình 9: Trực quan hóa tỷ lệ giá trị thiếu của các thuộc tính có thiếu trong dữ liệu gốc.

Bảng 8: Tổng hợp giá trị thiếu theo bảy bảng

Bảng dữ liệu	Số cột	Số giá trị thiếu	Tổng số ô	Tỷ lệ giá trị thiếu (%)
`courses`	3	0	66	0,00
`assessments`	6	11	1.236	0,89
`studentInfo`	12	1.111	391.116	0,28
`studentRegistration`	5	22.566	162.965	13,85
`studentAssessment`	5	173	869.560	0,02
`vle`	6	10.486	38.184	27,46
`studentVle`	6	0	63.931.680	0,00

Bảng 9: Các thuộc tính có giá trị thiếu trong dữ liệu thô

Bảng dữ liệu	Cột dữ liệu	Số giá trị thiếu	Tỷ lệ giá trị thiếu (%)
`assessments`	`date`	11	5,34
`studentInfo`	`imd_band`	1.111	3,41
`studentRegistration`	`date_registration`	45	0,14
`studentRegistration`	`date_unregistration`	22.521	69,10
`studentAssessment`	`score`	173	0,10
`vle`	`week_from`	5.243	82,39
`vle`	`week_to`	5.243	82,39

Ngày rút học phần trống có thể là thông tin nghiệp vụ "chưa ghi nhận rút", còn tuần hiển thị tài nguyên trống không đồng nghĩa với ngày tương tác trống. Vì vậy các thuộc tính thiếu cần quy tắc riêng, không dùng một phương pháp điền cho tất cả.

Đối với `assessments`, các trường hợp thiếu hạn nộp đều thuộc loại Exam. Do không có căn cứ xác định ngày thi thực tế, các giá trị này không được thay bằng thời lượng học phần.

Bảng 10: Bài đánh giá thiếu hạn nộp theo loại

Loại bài đánh giá	Số bài đánh giá	Số bài có hạn nộp	Số bài thiếu hạn nộp	Tỷ lệ bài thiếu hạn nộp (%)
CMA	76	76	0	0,00
Exam	24	13	11	45,83
TMA	106	106	0	0,00

2.3.2. Kiểm tra bản ghi trùng lặp

Trùng hoàn toàn là các dòng giống nhau trên tất cả cột nguồn, đếm số dòng dư từ lần xuất hiện thứ hai. Với bảng nhật ký lớn, phép kiểm tra bao phủ các khối đọc thay vì chỉ so trong từng khối.

Bảng 11: Bản ghi dư trùng hoàn toàn trong bảy bảng

Bảng dữ liệu	Số bản ghi	Số bản ghi trùng lặp dư	Tỷ lệ bản ghi trùng lặp dư (%)	Phạm vi
`courses`	22	0	0,00	Toàn bảng
`assessments`	206	0	0,00	Toàn bảng
`studentInfo`	32.593	0	0,00	Toàn bảng
`studentRegistration`	32.593	0	0,00	Toàn bảng
`studentAssessment`	173.912	0	0,00	Toàn bảng
`vle`	6.364	0	0,00	Toàn bảng
`studentVle`	10.655.280	787.170	7,39	Toàn bảng; xuyên khối

Bảng 12: Kiểm tra tính duy nhất của khóa kỳ vọng

Bảng dữ liệu	Số bản ghi	Số bản ghi thiếu thành phần khóa	Số bản ghi thuộc nhóm trùng khóa
`courses`	22	0	0
`assessments`	206	0	0
`studentInfo`	32.593	0	0
`studentRegistration`	32.593	0	0
`studentAssessment`	173.912	0	0
`vle`	6.364	0	0

Các phép kiểm tra khóa kỳ vọng không ghi nhận vi phạm tính duy nhất. Đối với `studentVle`, các bản ghi trùng hoàn toàn chưa đủ căn cứ để xác định lỗi thu thập; quyết định loại bỏ cần dựa trên quy tắc nghiệp vụ ngoài kết quả của hàm `duplicated()`.

2.3.3. Kiểm tra giá trị không hợp lệ và ngoại lai

Việc đánh giá miền giá trị sử dụng **62 quy tắc kiểm tra**, bao gồm định dạng mã, tính nguyên của biến đếm và ngày, miền điểm/trọng số và tập giá trị của biến phân loại. Không phát hiện vi phạm trong phạm vi các quy tắc đã xây dựng. Kết quả này không loại trừ hoàn toàn những bất thường nghiệp vụ nằm ngoài bộ quy tắc.

Ứng viên ngoại lai được kiểm tra riêng bằng quy tắc Tukey:

$$\mathrm{IQR} = Q_3 - Q_1, \qquad [L, U] = [Q_1 - 1{,}5\,\mathrm{IQR},\ Q_3 + 1{,}5\,\mathrm{IQR}]. \tag{1}$$

Bảng 13: Ứng viên ngoại lai theo quy tắc Tukey

Cột dữ liệu	Q1	Q3	Ngưỡng dưới	Ngưỡng trên	Số giá trị dưới ngưỡng	Số giá trị trên ngưỡng
`score`	65,00	90,00	27,50	127,50	3.813	0
`studied_credits`	60,00	120,00	−30,00	210,00	0	350
`num_of_prev_attempts`	0,00	0,00	0,00	0,00	0	4.172
`sum_click`	1,00	3,00	−2,00	6,00	0	1.314.646

Biến `sum_click` có 1.314.646 bản ghi vượt ngưỡng IQR bằng 6 click. Đối với `num_of_prev_attempts`, Q1 = Q3 = 0 khiến mọi giá trị dương đều được đánh dấu. Các trường hợp này được xem là ứng viên ngoại lai về mặt thống kê, chưa phải lỗi dữ liệu đã được xác minh.

2.3.4. Kiểm tra tính nhất quán và khả năng liên kết

Các phép đối chiếu khóa ngoại đều dùng đủ ngữ cảnh học phần–đợt học, có kiểm tra tính duy nhất của khóa cha. Trên **11 hướng đối chiếu**, không phát hiện dòng con không khớp.

Bảng 14: Tổng hợp đối chiếu tính toàn vẹn khóa ngoại

Bảng con / phạm vi	Bảng cha	Số bản ghi thiếu khóa liên kết	Số bản ghi không liên kết được
`assessments`	`courses`	0	0
`studentInfo`	`courses`	0	0
`studentRegistration`	`courses`	0	0
`vle`	`courses`	0	0
`studentRegistration`	`studentInfo`	0	0
`studentInfo`	`studentRegistration`	0	0
`studentAssessment`	`assessments`	0	0
`studentAssessment` (đã tra đợt học từ `assessments`)	`studentInfo`	0	0
`studentVle` (toàn bộ)	`courses`	0	0
`studentVle` (toàn bộ)	`studentInfo`	0	0
`studentVle` (toàn bộ)	`vle`	0	0

Bảng 15: Các kiểm tra nhất quán trạng thái, thời gian và nhãn

Kiểm tra	Số trường hợp	Tỷ lệ (%)	Diễn giải
Ngày đăng ký sau ngày rút học	0	0,00	Vi phạm thứ tự thời gian; cần truy nguyên
Có ngày rút học nhưng `final_result` khác Withdrawn	9	0,09	Rà soát ngữ cảnh trạng thái; chưa tự kết luận lỗi
`final_result` Withdrawn nhưng thiếu ngày rút	93	0,92	Rà soát mức đầy đủ của mốc rút học
Ngày đăng ký âm	32.312	99,27	Có thể hợp lệ: đăng ký trước ngày bắt đầu
Ngày rút sau thời lượng đợt học	1	0,01	Rà soát ngữ cảnh hành chính, không tự xóa
`week_from` > `week_to`	0	0,00	Vi phạm thứ tự tuần nếu có đủ hai mốc
Log VLE: Trước ngày bắt đầu	688.988	6,47	Mốc ngày tương đối; chỉ mô tả, chưa loại dòng

Còn tiếp trang sau

Tiếp Bảng 15

Kiểm tra	Số trường hợp	Tỷ lệ (%)	Diễn giải
Log VLE: Trong thời lượng đợt học	9.966.292	93,53	Mốc ngày tương đối; chỉ mô tả, chưa loại dòng
Log VLE: Sau thời lượng đợt học	0	0,00	Mốc ngày tương đối; chỉ mô tả, chưa loại dòng
Log VLE: Không xác định	0	0,00	Mốc ngày tương đối; chỉ mô tả, chưa loại dòng
`imd_band`: nhãn không có hậu tố % (khác đa số nhóm)	3.516	11,17	Khác quy ước nhãn nguồn; chưa chuẩn hóa

Trong bảng đánh giá tính nhất quán, 11,17% là tỷ lệ của 3.516 lượt học mang nhãn IMD `10-20` trên 31.482 lượt học có IMD xác định (32.593 trừ 1.111 trường hợp thiếu). Vì vậy, tỷ lệ này khác 10,79% tại bảng phân phối nhân khẩu học do sử dụng mẫu số khác nhau.

Có 688.988 bản ghi tương tác trước ngày bắt đầu đợt học; những sự kiện này không được phân loại mặc nhiên là lỗi. Một số trường hợp ngày rút và `final_result` chưa nhất quán hoàn toàn được lưu để đối chiếu. Tổng trọng số bài đánh giá không nhất thiết bằng 100% trong từng nhóm loại bài; vì vậy chưa thực hiện điều chỉnh trọng số khi thiếu căn cứ nghiệp vụ.

2.4. Tổng hợp kết quả và đề xuất tiền xử lý

2.4.1. Tổng hợp các vấn đề chất lượng dữ liệu

Các phát hiện được phân thành: giá trị thiếu cần diễn giải theo nghiệp vụ, quan sát khác biệt thống kê nhưng chưa chắc sai, và các vi phạm cần kiểm tra theo quy tắc. Những tỷ lệ trong các bảng có thể dùng mẫu số khác nhau và không được cộng để tạo tổng tỷ lệ lỗi.

Bảng 16: Tổng hợp các vấn đề chất lượng dữ liệu thô

Nhóm vấn đề	Phạm vi	Số lượng	Tỷ lệ (%)	Đánh giá
Giá trị thiếu	`vle` `week_to`	5.243	82,39	Cần phân biệt thiếu cấu trúc và thiếu thông tin
Giá trị thiếu	`vle` `week_from`	5.243	82,39	Cần phân biệt thiếu cấu trúc và thiếu thông tin
Giá trị thiếu	`studentRegistration` `date_unregistration`	22.521	69,10	Cần phân biệt thiếu cấu trúc và thiếu thông tin
Giá trị thiếu	`assessments` `date`	11	5,34	Cần phân biệt thiếu cấu trúc và thiếu thông tin
Giá trị thiếu	`studentInfo` `imd_band`	1.111	3,41	Cần phân biệt thiếu cấu trúc và thiếu thông tin

Còn tiếp trang sau

Tiếp Bảng 16

Nhóm vấn đề	Phạm vi	Số lượng	Tỷ lệ (%)	Đánh giá
Giá trị thiếu	`studentRegistration` `date_registration`	45	0,14	Cần phân biệt thiếu cấu trúc và thiếu thông tin
Giá trị thiếu	`studentAssessment` `score`	173	0,10	Cần phân biệt thiếu cấu trúc và thiếu thông tin
Trùng toàn dòng	`studentVle`	787.170	7,39	Cần xác minh nguồn, chưa xóa
Vi phạm miền	62 phép kiểm tra	0	0,00	Không phát hiện theo các quy tắc đã áp dụng
Không khớp quan hệ	11 phép kiểm tra	0	0,00	Không phát hiện theo các quy tắc đã áp dụng
Trùng khóa kỳ vọng	6 phép kiểm tra	0	0,00	Không phát hiện theo các quy tắc đã áp dụng
Ứng viên ngoại lai IQR	`studentAssessment` `score`	3.813	2,19	Cờ thống kê; chưa xác định là lỗi
Ứng viên ngoại lai IQR	`studentInfo` `studied_credits`	350	1,07	Cờ thống kê; chưa xác định là lỗi
Ứng viên ngoại lai IQR	`studentInfo` `num_of_prev_attempts`	4.172	12,80	Cờ thống kê; chưa xác định là lỗi
Ứng viên ngoại lai IQR	`studentVle` `sum_click`	1.314.646	12,34	Cờ thống kê; chưa xác định là lỗi
Cần rà soát ngữ cảnh	Có ngày rút học nhưng `final_result` khác Withdrawn	9	0,09	Rà soát ngữ cảnh trạng thái; chưa tự kết luận lỗi
Cần rà soát ngữ cảnh	`final_result` Withdrawn nhưng thiếu ngày rút	93	0,92	Rà soát mức đầy đủ của mốc rút học
Cần rà soát ngữ cảnh	Ngày rút sau thời lượng đợt học	1	0,01	Rà soát ngữ cảnh hành chính, không tự xóa
Cần rà soát ngữ cảnh	`imd_band`: nhãn không có hậu tố % (khác đa số nhóm)	3.516	11,17	Khác quy ước nhãn nguồn; chưa chuẩn hóa

Đối với bất thường định dạng nhãn IMD, tỷ lệ 11,17% tiếp tục sử dụng mẫu số 31.482 lượt học có thông tin IMD. Tỷ lệ theo toàn bộ 32.593 lượt học là 10,79%; số lượng tương ứng trong cả hai phép tính đều là 3.516.

2.4.2. Đề xuất phương án tiền xử lý

Các đề xuất trong Phần 2 là đầu vào quyết định cho Phần 3. Những giá trị thiếu có nghĩa cấu trúc không tự động điền bằng trung bình hoặc trung vị; các giá trị cao hợp lệ không tự động bị loại; nhãn cuối kỳ phải giữ tách khỏi thông tin biết tại thời điểm cảnh báo.

Bảng 17: Đề xuất tiền xử lý theo vấn đề đã phát hiện

Phạm vi	Căn cứ thực tế	Đề xuất cho giai đoạn sau
`vle` `week_to`	5.243 ô thiếu (82,39%)	Đánh giá cùng `week_from`; không suy diễn tuần kết thúc chỉ từ thống kê chung.
`vle` `week_from`	5.243 ô thiếu (82,39%)	Cân nhắc không dùng lịch tuần hoặc giữ thiếu có cấu trúc; chỉ điền khi có căn cứ nghiệp vụ.
`studentRegistration` `date_unregistration`	22.521 ô thiếu (69,10%)	Giữ ý nghĩa không ghi nhận rút học; đối chiếu trạng thái. Không mặc định điền 0 hoặc dùng thông tin tương lai.
`assessments` `date`	11 ô thiếu (5,34%)	Tách ngữ cảnh Exam và bài trong kỳ; không điền ngày chung khi chưa có căn cứ.
`studentInfo` `imd_band`	1.111 ô thiếu (3,41%)	Cân nhắc nhóm `Unknown` hoặc phương án điền phù hợp; so sánh trên train, bảo toàn cờ thiếu nếu có ích.
`studentRegistration` `date_registration`	45 ô thiếu (0,14%)	Rà soát từng lượt thiếu; không tự suy diễn ngày hoặc thay bằng 0.
`studentAssessment` `score`	173 ô thiếu (0,10%)	Phân biệt chưa có điểm và điểm 0; chỉ chọn chiến lược khi đã xác minh thời điểm công bố.
Trùng toàn dòng	787.170 dòng dư trong 7 bảng	Nếu xác minh là lỗi ghi nhận mới loại đúng dòng trùng; với log, xem xét quy trình thu thập trước.
Giá trị không hợp lệ và khóa ngoại	0 lượt vi phạm miền; 0 lượt không khớp quan hệ	Truy nguyên trường hợp vi phạm trước khi sửa/loại; giữ kiểm tra khóa many-to-one khi nối thống kê.
Ngoại lai IQR	`score`: 3.813; `studied_credits`: 350; `num_of_prev_attempts`: 4.172; `sum_click`: 1.314.646	Ưu tiên giữ giá trị hợp lệ; cân nhắc log hoặc mô hình bền vững nếu phù hợp, đánh giá trên tập train.
IMD: cách ghi nhãn	Nhãn không có hậu tố %: 10-20	Nếu cần thứ tự nhóm IMD, định nghĩa ánh xạ rõ ràng và lưu từ điển; hiện giữ nguyên nhãn.

Còn tiếp trang sau

Tiếp Bảng 17

Phạm vi	Căn cứ thực tế	Đề xuất cho giai đoạn sau
`final_result` và chia tập	4 lớp gốc; 28.785 sinh viên / 32.593 lượt học	Giữ nguyên bốn nhãn gốc; cân nhắc chia theo thời gian/đợt học và tránh cùng sinh viên gây rò rỉ giữa các tập khi triển khai `modeling ipynb` .
Mốc ngày và khả dụng thông tin	688.988 log trước ngày bắt đầu; 0 log sau thời lượng	Chốt cửa sổ quan sát, xem xét ngày âm; không dùng kết quả cuối kỳ/ngày rút học tương lai làm đầu vào. Ngày nộp không đảm bảo ngày có điểm.
Mã hóa, điền thiếu, chuẩn hóa và tích hợp	43 cột được khảo sát trên 7 bảng	Chọn biến, tổng hợp đúng đơn vị lượt học; chỉ fit các phép học tham số trên train sau khi chia tập. Chưa triển khai tại đây.
Cảnh báo sớm theo 5 mốc	Dữ liệu có ngày tương đối; không có ngày công bố điểm	Xây dựng đặc trưng tại tuần 4. 8. 12. 16. 24 (ngày 0-−27. 0-−55. 0-−83. 0-−111. 0-−167). Chỉ dùng thông tin biết được tại cutoff.

Các phương án đề xuất được đối chiếu với kết quả xử lý thực tế tại Phần 3, bảo đảm phân biệt giữa vấn đề đã phát hiện và thao tác đã triển khai.

Phần 3. Tiền xử lý và tích hợp dữ liệu OULAD

Quy trình tiền xử lý được triển khai trên bản sao dữ liệu gốc, căn cứ vào kết quả đánh giá chất lượng ở Phần 2. Đầu ra gồm các tập dữ liệu phục vụ bài toán *cảnh báo sớm*, với đơn vị quan sát là một lượt học tại một mốc dự đoán xác định. Việc chia tập, mã hóa biến phân loại, chuẩn hóa dựa trên thống kê tập huấn luyện và xây dựng mô hình thuộc giai đoạn nghiên cứu tiếp theo.

3.1. Xác định phạm vi và phương án tiền xử lý

3.1.1. Xác định dữ liệu đầu vào và biến mục tiêu

Bảy bảng nguồn được phân chia theo chức năng: `studentInfo` và `studentRegistration` xác định lượt học; `courses` cung cấp thông tin học phần; `assessments` và `studentAssessment` ghi nhận bài đánh giá và bài nộp; `vle` và `studentVle` mô tả tài nguyên học tập và lịch sử tương tác. Dữ liệu sự kiện được tổng hợp theo khóa lượt học trước khi tích hợp nhằm bảo toàn đơn vị quan sát.

Bảng 18: Vai trò của từng bảng trong quy trình cảnh báo sớm

Bảng dữ liệu	Nội dung bảng	Số bản ghi	Vai trò ở Phần 3
`courses`	Học phần, đợt mở lớp và thời lượng	22	Thời lượng đợt học
`assessments`	Bài đánh giá, hạn nộp và trọng số	206	Loại bài và hạn nộp
`studentInfo`	Thông tin sinh viên và kết quả học tập	32.593	Bảng cơ sở; `final_result` là nhãn
`studentRegistration`	Ngày đăng ký và ngày rút học phần	32.593	Điều kiện còn tham gia tại cutoff; ngày đăng ký
`studentAssessment`	Ngày nộp bài và điểm đánh giá	173.912	Sự kiện bài nộp; không dùng `score`
`vle`	Tài nguyên, loại hoạt động và lịch tuần	6.364	Ánh xạ tài nguyên sang `activity_type`
`studentVle`	Nhật ký tương tác và số lượt nhấp	10.655.280	Tổng hợp tương tác theo ngày và cutoff

Biến đích y là `final_result` với đủ bốn nhãn gốc. Đầu vào X gồm các thuộc tính nền và các đặc trưng được tạo từ dữ liệu tại hoặc trước thời điểm dự đoán. Nhãn cuối kỳ không được dùng để quyết định một người học có thuộc nhóm dự đoán ở thời điểm quá khứ hay không.

3.1.2. Xác định phạm vi dữ liệu và các mốc dự đoán

Năm mốc cảnh báo là tuần 4, 8, 12, 16 và 24. Tuần được tính theo ngày tương đối, với cửa sổ sự kiện bắt đầu tại ngày 0 và *bao gồm cả ngày chốt*. Do đó ngày chốt tương ứng là 27, 55, 83, 111 và 167.

Bảng 19: Cấu hình năm mốc dự đoán

Mốc dự đoán (tuần)	Ngày bắt đầu quan sát	Ngày chốt dữ liệu
4	0	27
8	0	55
12	0	83
16	0	111
24	0	167

Một lượt học đủ điều kiện tại ngày chốt t khi ngày đăng ký hợp lệ không muộn hơn t và chưa có ghi nhận rút học phần vào hoặc trước ngày này. Trường hợp rút đúng ngày chốt được phân loại là đã rút. Giá trị thiếu ở ngày rút được diễn giải theo quy ước *chưa ghi nhận rút*, nhưng không xác nhận chắc chắn trạng thái hoạt động thực tế. Ngày rút sau mốc dự đoán không tham gia xây dựng X.

Bảng 20: Phân biệt điều kiện tham gia, nhãn và thông tin đưa vào X

Cột dữ liệu	**Vai trò**	**Điều kiện sử dụng thông tin**
`final_result`	Nhãn y	Không đưa vào X; không dùng để chọn nhóm lượt học đủ điều kiện
`date_registration`	Điều kiện chọn nhóm và đặc trưng nền	Phải biết và $\leq$ cutoff
`date_unregistration`	Chỉ dùng để chọn nhóm lượt học	Không xuất vào tập đặc trưng theo tuần
`score`	Chỉ kiểm toán dữ liệu nguồn	Không dùng do thiếu ngày công bố điểm
`studentVle` `date_submitted`, `date`	Thời điểm sự kiện	Chỉ dùng sự kiện ngày $[0, t]$
`assessments` `date`	Hạn nộp để xét muộn	Chỉ xét hạn xác định và $\leq$ cutoff

Biến `score` bị loại khỏi X do thời điểm nộp bài không xác định được thời điểm công bố điểm. Đối với các thuộc tính nền, quy trình giả định thông tin đã sẵn có tại mốc cảnh báo; OULAD không cung cấp lịch sử cập nhật của các thuộc tính này.

3.1.3. Tổng hợp phương án xử lý

Phương án xử lý được xác lập dựa trên mức độ đầy đủ, tính hợp lệ, khả năng liên kết và yêu cầu loại trừ thông tin tương lai. Bảng 21 đối chiếu từng vấn đề chất lượng với biện pháp xử lý đã áp dụng.

Bảng 21: Kế hoạch tiền xử lý đã lựa chọn

Bảng dữ liệu	Cột dữ liệu	Số lượng ảnh hưởng	Phương án xử lý	Lý do
vle	week_to	5.243	Giữ NA; không dùng lịch tuần dự kiến làm đặc trưng	Có ngày tương tác thực tế nên vẫn tổng hợp được hoạt động mà không cần tuần kết thúc dự kiến.
vle	week_from	5.243	Giữ NA; không dùng lịch tuần dự kiến làm đặc trưng	Có ngày tương tác thực tế nên vẫn tổng hợp được hoạt động mà không cần tuần bắt đầu dự kiến.
studentRegistration	date_unregistration	22.521	Giữ trống ngày rút; vẫn đưa vào nhóm dự đoán nếu đã biết ngày đăng ký và ngày đó không sau mốc.	Không biết ngày rút nên chưa xác định được đã rút tại mốc hay chưa; tạm giữ lượt học theo giả định chưa ghi nhận rút.
assessments	date	11	Giữ NA; bỏ khỏi mẫu số xét muộn khi hạn không xác định	Không biết hạn nộp nên không xác định được bài nộp đúng hạn hay muộn.
studentInfo	imd_band	1.111	Nhóm Unknown và cờ imd_band_missing	Chưa biết nhóm IMD thực tế; dùng Unknown để giữ lượt học mà không tự đoán nhóm.
studentRegistration	date_registration	45	Giữ trống ngày đăng ký trong bảng cơ sở; không đưa lượt học vào các tập dự đoán theo tuần.	Không biết ngày đăng ký nên chưa xác định được đã đăng ký trước hoặc tại mốc dự đoán hay chưa.

Còn tiếp trang sau

Tiếp Bảng 21

Bảng dữ liệu	Cột dữ liệu	Số lượng ảnh hưởng	Phương án xử lý	Lý do
`studentAssessment`	`score`	173	Giữ NA; không dùng bất kỳ `score` nào làm đặc trưng	Không biết khi nào điểm được công bố nên chưa chắc điểm đã có tại mốc dự đoán.
`studentVle`	Toàn bộ cột	787.170	Giữ nguyên log, kể cả dòng trùng	Các dòng giống nhau chưa đủ để kết luận bị ghi lặp do lỗi; cần xác minh trước khi xóa.
`studentInfo`	`studied_credits`	350	Giữ nguyên giá trị	Giá trị cao hoặc ít gặp chưa có nghĩa là sai; chưa đủ căn cứ để sửa hoặc xóa.
`studentInfo`	`num_of_prev_attempts`	4.172	Giữ nguyên giá trị	Giá trị cao hoặc ít gặp chưa có nghĩa là sai; chưa đủ căn cứ để sửa hoặc xóa.
`studentVle`	`sum_click`	1.314.646	Giữ nguyên giá trị	Giá trị cao hoặc ít gặp chưa có nghĩa là sai; chưa đủ căn cứ để sửa hoặc xóa.

3.2. Xử lý giá trị thiếu

3.2.1. Xử lý giá trị thiếu trong studentInfo

Các giá trị thiếu của `imd_band` được gán nhãn danh mục `Unknown`, đồng thời bổ sung biến chỉ báo `imd_band_missing` (giá trị 1 tương ứng với trường hợp thiếu ban đầu, giá trị 0 tương ứng với trường hợp có thông tin). Phương án này bảo toàn lượt học, đồng thời phân biệt trạng thái thiếu với các nhóm IMD xác định. Số lượng thay đổi được tổng hợp tại Bảng 22.

Bảng 22: Kết quả xử lý nhóm IMD thiếu

Bảng dữ liệu	Cột dữ liệu	Số giá trị thiếu trước xử lý	Số giá trị thiếu sau xử lý	Số giá trị `Unknown` sau xử lý	Số lượt học sau xử lý
`studentInfo`	`imd_band`	1.111	0	1.111	32.593

3.2.2. Xử lý giá trị thiếu trong studentRegistration

Các lượt học thiếu `date_registration` vẫn được lưu trong bảng cơ sở nhằm bảo toàn dữ liệu phục vụ đối chiếu, nhưng không được đưa vào tập dự đoán do không xác định được điều kiện tham gia tại ngày chốt. Các giá trị thiếu của `date_unregistration` được giữ nguyên; nhãn cuối kỳ `Withdrawn` không được sử dụng để suy diễn ngày rút.

Bảng 23: Cách xử lý thiếu ngày đăng ký và ngày rút

Cột dữ liệu	Số giá trị thiếu	Phương án xử lý
`date_registration`	45	Giữ trống ngày đăng ký trong bảng cơ sở; không đưa lượt học vào các tập dự đoán theo tuần.
`date_unregistration`	22.521	Giữ trống ngày rút; vẫn đưa vào nhóm dự đoán nếu đã biết ngày đăng ký và ngày đó không sau mốc.

3.2.3. Xử lý giá trị thiếu trong studentAssessment, assessments và vle

Trong `studentAssessment`, 173 giá trị `score` thiếu được giữ nguyên do chưa có căn cứ lựa chọn giá trị thay thế. Hạn nộp của 11 bài `Exam` cũng không được nội suy vì thiếu thông tin về lịch thi thực tế. Đối với dữ liệu VLE, tương tác được tổng hợp theo ngày xảy ra sự kiện, không phụ thuộc vào việc điền giá trị thiếu của thời gian xuất hiện tài nguyên.

Bảng 24: Quy tắc xử lý các giá trị thiếu còn lại

Bảng dữ liệu	Cột dữ liệu	Số lượng ảnh hưởng	Phương án xử lý	Lý do
`vle`	`week_to`	5.243	Giữ NA; không dùng lịch tuần dự kiến làm đặc trưng	Có ngày tương tác thực tế nên vẫn tổng hợp được hoạt động mà không cần tuần kết thúc dự kiến.
`vle`	`week_from`	5.243	Giữ NA; không dùng lịch tuần dự kiến làm đặc trưng	Có ngày tương tác thực tế nên vẫn tổng hợp được hoạt động mà không cần tuần bắt đầu dự kiến.
`assessments`	`date`	11	Giữ NA; bỏ khỏi mẫu số xét muộn khi hạn không xác định	Không biết hạn nộp nên không xác định được bài nộp đúng hạn hay muộn.
`studentAssessment`	`score`	173	Giữ NA; không dùng bất kỳ `score` nào làm đặc trưng	Không biết khi nào điểm được công bố nên chưa chắc điểm đã có tại mốc dự đoán.

3.2.4. Kiểm tra kết quả xử lý giá trị thiếu

Đối chiếu trước và sau xử lý ghi nhận 1.111 giá trị `imd_band` được chuyển từ thiếu sang nhãn `Unknown`. Các trường khác tiếp tục giữ giá trị thiếu theo quy tắc nghiệp vụ đã xác định. Vì vậy, số lượng giá trị thiếu còn lại được diễn giải theo nguyên nhân và vai trò thuộc tính, thay vì xem toàn bộ là lỗi chưa được xử lý.

Bảng 25: Giá trị thiếu trước và sau tiền xử lý

Bảng dữ liệu	Cột dữ liệu	Số giá trị thiếu trước xử lý	Số giá trị thiếu sau xử lý	Phương án đã áp dụng
`studentInfo`	`imd_band`	1.111	0	Nhóm `Unknown` và cờ `imd_band_missing`
`studentRegistratio`	`date_registration`	45	45	Giữ trống ngày đăng ký trong bảng cơ sở; không đưa lượt học vào các tập dự đoán theo tuần.
`studentRegistration`	`date_unregistration`	22.521	22.521	Giữ trống ngày rút; vẫn đưa vào nhóm dự đoán nếu đã biết ngày đăng ký và ngày đó không sau mốc.
`studentAssessment`	`score`	173	173	Giữ NA; không dùng bất kỳ `score` nào làm đặc trưng
`assessments`	`date`	11	11	Giữ NA; bỏ khỏi mẫu số xét muộn khi hạn không xác định
`vle`	`week_from`	5.243	5.243	Giữ NA; không dùng lịch tuần dự kiến làm đặc trưng
`vle`	`week_to`	5.243	5.243	Giữ NA; không dùng lịch tuần dự kiến làm đặc trưng

3.3. Xử lý dữ liệu trùng lặp, không hợp lệ và ngoại lai

3.3.1. Xử lý bản ghi trùng lặp

Không ghi nhận khóa trùng trong sáu bảng có khóa kỳ vọng. Các bản ghi trùng hoàn toàn của nhật ký VLE được giữ nguyên do chưa có bằng chứng xác nhận lỗi thu thập. Quyết định này được tính đến khi diễn giải các đặc trưng tổng số lượt click.

Bảng 26: Kết quả xử lý các nhóm bản ghi trùng

Bảng dữ liệu	Số bản ghi trùng lặp dư	Số bản ghi trùng sai đã loại	Phương án xử lý
courses	0	0	Không có trùng hoàn toàn để xử lý
assessments	0	0	Không có trùng hoàn toàn để xử lý
studentInfo	0	0	Không có trùng hoàn toàn để xử lý
studentRegistratior	0	0	Không có trùng hoàn toàn để xử lý
studentAssessment	0	0	Không có trùng hoàn toàn để xử lý
vle	0	0	Không có trùng hoàn toàn để xử lý
studentVle	787.170	0	Giữ log trùng chưa xác minh; không tự gộp/xóa

3.3.2. Xử lý giá trị không hợp lệ

Cả 62 quy tắc kiểm tra miền giá trị được xây dựng tại Phần 2 đều không ghi nhận vi phạm trên dữ liệu quan sát. Vì vậy, không phát sinh thao tác chỉnh sửa hoặc loại bỏ bản ghi do vi phạm miền. Các giá trị ngày âm được bảo toàn trong dữ liệu nguồn; việc giới hạn sự kiện từ ngày 0 chỉ nhằm xác định *cửa sổ quan sát phục vụ dự đoán*.

Bảng 27: Đối chiếu giá trị không hợp lệ

Bảng dữ liệu	Số quy tắc đã kiểm tra	Số lượt vi phạm	Phương án xử lý
courses	5	0	Không sửa/loại vì chưa phát hiện vi phạm theo quy tắc
assessments	9	0	Không sửa/loại vì chưa phát hiện vi phạm theo quy tắc
studentInfo	20	0	Không sửa/loại vì chưa phát hiện vi phạm theo quy tắc
studentRegistratior	7	0	Không sửa/loại vì chưa phát hiện vi phạm theo quy tắc
studentAssessment	5	0	Không sửa/loại vì chưa phát hiện vi phạm theo quy tắc
vle	8	0	Không sửa/loại vì chưa phát hiện vi phạm theo quy tắc
studentVle	8	0	Không sửa/loại vì chưa phát hiện vi phạm theo quy tắc

3.3.3. Xử lý giá trị ngoại lai

Các giá trị được đánh dấu là ứng viên ngoại lai của `sum_click`, `studied_credits` và `num_of_prev_attempts` vẫn được giữ nguyên, do tiêu chí IQR không đủ để kết luận sai lệch nghiệp vụ. Quy trình không áp dụng cắt ngưỡng, thay thế bằng trung vị, winsorize hoặc loại bỏ quan sát dựa riêng trên IQR. Nhu cầu biến đổi thang đo sẽ được đánh giá trong giai đoạn mô hình hóa sau khi chia tập dữ liệu.

Bảng 28: Quyết định đối với ứng viên ngoại lai

Cột dữ liệu	Ngưỡng dưới	Ngưỡng trên	Số giá trị trên ngưỡng	Phương án xử lý
`studied_credits`	−30,00	210,00	350	Giữ nguyên; chưa có bằng chứng giá trị sai
`num_of_prev_attempts`	0,00	0,00	4.172	Giữ nguyên; chưa có bằng chứng giá trị sai
`sum_click`	−2,00	6,00	1.314.646	Giữ nguyên; chưa có bằng chứng giá trị sai

3.4. Chuẩn hóa cấu trúc và định dạng dữ liệu

3.4.1. Chuẩn hóa kiểu dữ liệu

Các trường mã định danh và các trường ngày/số đếm có tính nguyên được kiểm tra trước khi chuyển sang kiểu `Int64` hỗ trợ giá trị thiếu. Các nhãn được thống nhất kiểu chuỗi; điểm và trọng số giữ kiểu số phù hợp. Các phép kiểm tra sau chuyển đổi đối chiếu lại cả giá trị và vị trí thiếu, tránh thay đổi dữ liệu không chủ ý.

Kết quả đối chiếu kiểu dữ liệu trước và sau chuyển đổi của 38 trường được trình bày tại Phụ lục B. Chuẩn hóa kiểu dữ liệu chỉ điều chỉnh hình thức lưu trữ; các phép mã hóa và chuẩn hóa thống kê có tham số học từ dữ liệu được dành cho giai đoạn huấn luyện.

3.4.2. Chuẩn hóa giá trị của các thuộc tính

Các nhãn nhóm IMD có sự khác biệt về cách ghi ký hiệu phần trăm được thống nhất định dạng. Quá trình chuẩn hóa giữ nguyên ý nghĩa của từng nhóm và không chuyển đổi biến phân loại thành biến thứ bậc.

Bảng 29: Thay đổi thực tế khi thống nhất cách ghi giá trị

Quy tắc	Số giá trị thay đổi	Ý nghĩa
Bỏ khoảng trắng đầu/cuối chuỗi	0	Không thay đổi nội dung nhãn
Thống nhất hậu tố % của nhóm IMD	3.516	10-20 được biểu diễn thành 10-20%; giữ nguyên nhóm khoảng và `Unknown`

3.4.3. Xử lý các thuộc tính thời gian

Không chuyển các giá trị ngày tương đối của OULAD sang ngày lịch thực tế. `date_registration` và `date_unregistration` được dùng để xác định điều kiện đủ tham gia; `date_submitted` và `studentVle.date` được dùng khi tổng hợp sự kiện trong cửa sổ $[0, t]$. `assessments.date` là hạn nộp, khác với ngày sinh viên thực sự nộp bài.

Đối với các đặc trưng nộp muộn, chỉ xét những bài đủ điều kiện có hạn đến ngày chốt. Ngày nộp hoặc hoạt động sau ngày chốt không được phép xuất hiện trong dữ liệu đầu vào ở mốc đó.

3.5. Tích hợp dữ liệu và xây dựng tập dữ liệu tổng hợp

3.5.1. Tích hợp thông tin sinh viên, đăng ký và học phần

Thực hiện ghép `studentInfo` với `studentRegistration` theo khóa lượt học, rồi bổ sung `courses` bằng mã học phần và đợt học. Các phép ghép được ràng buộc tính duy nhất và kiểm tra số dòng trước–sau, tránh mất lượt học hoặc nhân bản dòng.

Bảng 30: Kiểm tra bảng cơ sở `student_base`

Bảng dữ liệu	Số bản ghi	Số cột	Số bản ghi trùng khóa	Số bản ghi không liên kết được
`student_base`	32.593	16	0	0

Từ bảng cơ sở, các tập lượt học đủ điều kiện được xác định riêng tại từng ngày chốt. Những trường hợp không được chọn bao gồm thiếu ngày đăng ký, đăng ký sau ngày chốt hoặc đã rút học phần vào hoặc trước ngày chốt.

Bảng 31: Số lượt học đủ điều kiện ở năm mốc dự đoán

Mốc dự đoán (tuần)	Ngày chốt dữ liệu	Tổng số lượt học ban đầu	Số lượt học được chọn	Số lượt học thiếu ngày đăng ký
4	27	32.593	27.528	45
8	55	32.593	26.516	45
12	83	32.593	25.722	45
16	111	32.593	24.932	45
24	167	32.593	23.562	45

3.5.2. Tích hợp dữ liệu kết quả đánh giá theo các mốc dự đoán

Từ `studentAssessment` liên kết với `assessments`, quy trình chỉ tổng hợp sự kiện nộp TMA/CMA không chuyển điểm từ lần học trước (`is_banked`=0), có ngày nộp trong khoảng $[0, t]$. Các sự kiện được gom theo khóa lượt học *trước khi* ghép vào bảng cơ sở.

Nhóm đặc trưng bài nộp gồm: số bài nộp, số bài nộp có hạn đến ngày chốt, số bài nộp muộn và tỷ lệ muộn trong nhóm có hạn hợp lệ. Nếu chưa có bài đủ điều kiện làm mẫu số, `late_submission_rate` giữ thiếu có ý nghĩa cấu trúc, không tự thay bằng 0.

Bảng 32: Tổng hợp sự kiện nộp bài theo từng mốc

Mốc dự đoán (tuần)	Ngày chốt dữ liệu	Số lượt học trong bảng đặc trưng	Số bài nộp được dùng (toàn bộ cơ sở)	Số bài nộp có hạn đến ngày chốt
4	27	32.593	23.291	20.739
8	55	32.593	47.863	42.322
12	83	32.593	63.795	56.682
16	111	32.593	82.411	72.293
24	167	32.593	123.808	106.761

Bảng 33: Nhóm sự kiện bài nộp không được gộp

Điều kiện	Số bản ghi nguồn	Phương án xử lý
`is_banked` = 1	1.909	Không suy diễn là sự kiện nộp mới trong đợt học
Loại Exam	4.959	Không dùng trong đặc trưng bài nộp thông thường
TMA/CMA, không banked, nộp trước ngày 0	148	Ngoài cửa sổ quan sát đã chốt

3.5.3. Tích hợp dữ liệu tương tác VLE theo các mốc dự đoán

Nhật ký `studentVle` được xử lý theo khối và liên kết với danh mục `vle` bằng bộ khóa `code_module`, `code_presentation`, `id_site` để xác định `activity_type`. Các sự kiện trong khoảng $[0, t]$ sau đó được tổng hợp ở cấp lượt học, bao gồm tổng click, số ngày có hoạt động, số nhóm tài nguyên đã sử dụng, lượt click theo loại hoạt động và số click trung bình/ngày.

Bảng 34: Tổng hợp sự kiện VLE theo ngày chốt

Mốc dự đoán (tuần)	Ngày chốt dữ liệu	Số lượt học trong bảng đặc trưng	Số log được dùng (toàn bộ cơ sở)	Tổng số click trong cửa sổ	Số lượt học không có log trong cửa sổ
4	27	32.593	2.112.323	7.781.403	4.707
8	55	32.593	3.613.663	13.153.687	4.290
12	83	32.593	4.551.781	16.370.654	4.192
16	111	32.593	5.556.848	19.924.053	4.139
24	167	32.593	7.706.335	28.316.648	4.106

Việc tổng hợp nhật ký theo ngày chốt trước bước tích hợp bảo đảm mỗi lượt học chỉ có một dòng kết quả tại từng mốc. Tổng click, số ngày hoạt động và số nhóm hoạt động đã được đối chiếu độc lập trên các lượt học mẫu tại cả năm mốc.

3.5.4. Xác định bộ đặc trưng ban đầu và hợp nhất dữ liệu

Tập đặc trưng đầu vào sau tích hợp gồm ba nhóm: thông tin nền, hoạt động nộp bài và tương tác VLE. Tổng cộng 23 đặc trưng được xác lập theo cơ sở nghiệp vụ và khả năng quan sát tại ngày chốt; chưa áp dụng phương pháp lựa chọn đặc trưng dựa trên mô hình học máy. Danh mục, bảng nguồn và quy ước giá trị thiếu được trình bày tại Phụ lục C.

Bảng 35: Ba nhóm cấu thành 23 đặc trưng ứng viên

Nhóm	Số lượng	Ví dụ
Thông tin nền	11	`gender`, `age_band`, `studied_credits`, `imd_band_missing`
Bài nộp	4	`n_submissions`, `n_late_submissions`, `late_submission_rate`
VLE	8	`total_clicks`, `active_days`, `avg_clicks_per_day`, click theo loại tài nguyên

Các bảng tổng hợp được ghép bằng khóa lượt học theo quan hệ một–một. Mỗi tệp giữ tách biệt nhóm đặc trưng X, ba cột định danh, thông tin mốc dự đoán và nhãn y; không có `score` hoặc ngày rút trong X.

Bảng 36: Quy mô dữ liệu sau hợp nhất các nhóm đặc trưng

Mốc dự đoán (tuần)	Ngày chốt dữ liệu	Số lượt học sau ghép	Số cột	Số đặc trưng đầu vào (X)	Số bản ghi trùng khóa
4	27	27.528	29	23	0
8	55	26.516	29	23	0
12	83	25.722	29	23	0
16	111	24.932	29	23	0
24	167	23.562	29	23	0

3.5.5. Kiểm tra kết quả tích hợp

Kết quả đối chiếu số dòng trước và sau từng bước ghép xác nhận tính duy nhất của khóa lượt học trong các bảng tổng hợp; không ghi nhận sự gia tăng số dòng do liên kết nhiều–nhiều.

Bảng 37: Kiểm toán các bước ghép dữ liệu

Bước ghép	Số bản ghi trước	Số bản ghi sau	Số bản ghi liên kết được	Số bản ghi không liên kết được	Tỷ lệ liên kết (%)
`studentInfo` + `studentRegistration`	32.593	32.593	32.593	0	100,00
+ `courses`	32.593	32.593	32.593	0	100,00
`studentAssessment` + `assessments`	173.912	173.912	173.912	0	100,00
Tuần 4: + `assessment_features`	27.528	27.528	27.528	0	100,00
Tuần 4: + `vle_features`	27.528	27.528	27.528	0	100,00
Tuần 8: + `assessment_features`	26.516	26.516	26.516	0	100,00
Tuần 8: + `vle_features`	26.516	26.516	26.516	0	100,00
Tuần 12: + `assessment_features`	25.722	25.722	25.722	0	100,00
Tuần 12: + `vle_features`	25.722	25.722	25.722	0	100,00
Tuần 16: + `assessment_features`	24.932	24.932	24.932	0	100,00
Tuần 16: + `vle_features`	24.932	24.932	24.932	0	100,00
Tuần 24: + `assessment_features`	23.562	23.562	23.562	0	100,00
Tuần 24: + `vle_features`	23.562	23.562	23.562	0	100,00

Bảng 38: Giá trị thiếu còn lại sau tích hợp

Mốc dự đoán (tuần)	Cột dữ liệu	Số giá trị thiếu	Tỷ lệ giá trị thiếu (%)	Lý do
4	`late_submission_rate`	8.051	29,25	Số bài muộn / số bài có hạn đến cutoff; NA nếu mẫu số 0
8	`late_submission_rate`	4.497	16,96	Số bài muộn / số bài có hạn đến cutoff; NA nếu mẫu số 0
12	`late_submission_rate`	2.171	8,44	Số bài muộn / số bài có hạn đến cutoff; NA nếu mẫu số 0
16	`late_submission_rate`	1.961	7,87	Số bài muộn / số bài có hạn đến cutoff; NA nếu mẫu số 0
24	`late_submission_rate`	1.666	7,07	Số bài muộn / số bài có hạn đến cutoff; NA nếu mẫu số 0

Các số đếm bằng 0 là trường hợp chưa có sự kiện trong cửa sổ khi khóa nguồn đã đối chiếu được; khác với thiếu dữ liệu do ghép thất bại. Giá trị thiếu được chấp nhận còn lại là `late_submission_rate` khi mẫu số bằng 0.

3.6. Kiểm tra và đánh giá dữ liệu sau tiền xử lý

3.6.1. Đánh giá chất lượng dữ liệu sau xử lý

Các phép kiểm tra tự động được áp dụng đối với tính duy nhất của khóa, điều kiện tham gia, bảo toàn nhãn, miền giá trị và trạng thái thiếu hợp lệ. Thử nghiệm thay đổi các sự kiện phát sinh *sau* ngày chốt cho kết quả không thay đổi ở tập đầu vào và tập lượt học của các mốc trước đó.

Bảng 39: Kiểm tra không sử dụng thông tin sau cutoff

Mốc dự đoán (tuần)	Đặc trưng VLE không đổi khi thay dữ liệu sau mốc	Đặc trưng bài nộp không đổi khi thay dữ liệu sau mốc	Nhóm được chọn không đổi khi thay ngày rút sau mốc
4	Đạt	Đạt	Đạt
8	Đạt	Đạt	Đạt
12	Đạt	Đạt	Đạt
16	Đạt	Đạt	Đạt
24	Đạt	Đạt	Đạt

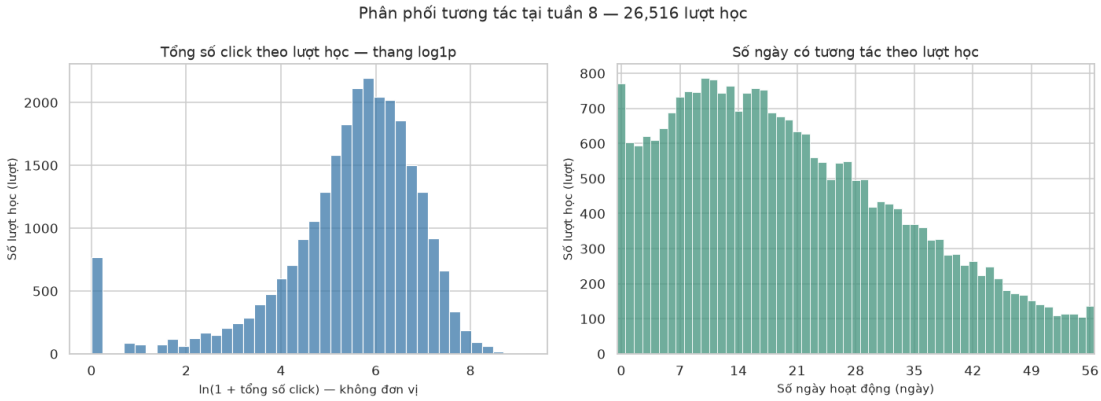
Cả năm mốc đều đạt các phép kiểm tra bất biến trước thay đổi của sự kiện tương lai, xác nhận việc áp dụng quy tắc ngày chốt lên dữ liệu sự kiện. Tuy nhiên, việc thiếu thời điểm công bố điểm và lịch sử cập nhật thuộc tính nền vẫn là giới hạn của khả năng kiểm chứng tính sẵn có của toàn bộ thông tin đầu vào.

3.6.2. So sánh dữ liệu trước và sau tiền xử lý

Quy mô tập dự đoán giảm dần ở các ngày chốt chủ yếu do thay đổi điều kiện tham gia theo thời gian, không xuất phát từ thao tác loại bỏ hàng loạt bản ghi thiếu IMD, chứa ứng viên ngoại lai hoặc trùng nhật ký VLE. Thành phần lượt học khác nhau giữa các mốc là yếu tố cần được xét đến khi so sánh thống kê.

Bảng 40: Quy mô lượt học trước và sau xử lý theo mốc

Mốc dự đoán (tuần)	Ngày chốt dữ liệu	Tổng số lượt học ban đầu	Số lượt học được chọn	Số lượt học bị loại tại mốc
4	27	32.593	27.528	5.065
8	55	32.593	26.516	6.077
12	83	32.593	25.722	6.871
16	111	32.593	24.932	7.661
24	167	32.593	23.562	9.031



Hình 10: Phân phối tổng click và số ngày hoạt động của các lượt học tại mốc tuần 8.

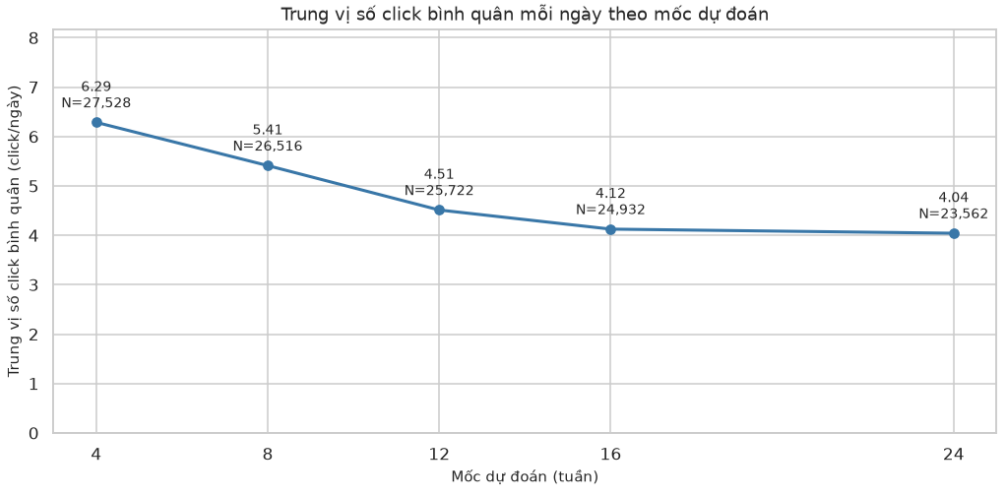
Bảng 41: Nhật ký những thay đổi dữ liệu thực sự được thực hiện

Thao tác	Số giá trị thay đổi	Đơn vị
Gán `Unknown` cho IMD thiếu	1.111	ô
Thống nhất cách ghi nhãn IMD	3.516	ô
Loại bản ghi trùng sai đã xác minh	0	bản ghi
Sửa/loại ngoại lai	0	giá trị

3.6.3. Khảo sát các đặc trưng tổng hợp sau tiền xử lý

Phân tích sau tiền xử lý sử dụng lượt học làm đơn vị quan sát, khác với phân phối `sum_click` theo bản ghi nhật ký gốc tại Phần 2. Các thống kê và biểu đồ được sử dụng để đánh giá phân phối, miền giá trị và tính hợp lý của các đặc trưng tổng hợp; việc lựa chọn đặc trưng cho mô hình được thực hiện ở giai đoạn tiếp theo.

Tại tuần 8, `total_clicks` có trung vị 303 và phân vị 95 bằng 1.532; 2,91% lượt học không ghi nhận click. Biến `active_days` có trung vị 18 ngày và cực đại 56 ngày, phù hợp với độ dài cửa sổ quan sát. Phép biến đổi `log1p` chỉ được áp dụng cho trục biểu diễn; giá trị lưu trong CSV không thay đổi.



Hình 11: Trung vị số click trung bình trên một ngày theo năm mốc cảnh báo.

Bảng 42: Lượt học chưa có bài nộp ở các mốc

Mốc dự đoán (tuần)	Số lượt học được chọn	Số lượt học chưa có bài nộp	Tỷ lệ lượt học chưa có bài nộp (%)
4	27.528	7.806	28,36
8	26.516	3.786	14,28
12	25.722	2.135	8,30
16	24.932	1.916	7,68
24	23.562	1.647	6,99

Tỷ lệ lượt học chưa ghi nhận bài nộp giảm từ 28,36% tại tuần 4 xuống 6,99% tại tuần 24. Kết quả phản ánh đồng thời sự mở rộng cửa sổ quan sát và thay đổi thành phần lượt học đủ điều kiện, không phải xu hướng theo dõi một đoàn hệ cố định.

Trung vị số click/ngày giảm từ 6,29 tại tuần 4 xuống 4,04 tại tuần 24. Chỉ số được tính trên toàn bộ số ngày trong cửa sổ, không chỉ trên ngày có hoạt động. Sự thay đổi của trung vị tổng hợp chưa đủ căn cứ để kết luận mức tương tác của từng người học suy giảm.

3.6.4. Lưu dữ liệu sau tiền xử lý theo từng mốc dự đoán

Quy trình lưu một bảng cơ sở `student_base` phục vụ đối chiếu và năm tệp dữ liệu tương ứng với các mốc dự đoán. Sau khi ghi, các tệp CSV được đọc lại để kiểm tra số dòng, số cột, khóa, nhãn và thông tin thời gian; dữ liệu gốc được bảo toàn. Các biến phân loại tiếp tục giữ giá trị nhãn nhằm bảo đảm việc mã hóa được thực hiện sau bước chia tập.

Bảng 43: Danh sách sáu tệp CSV xuất ra và quy mô

Tệp	Số bản ghi	Số cột	Dung lượng (MiB)
data/preprocessed/student_base.csv	32.593	16	2,94
data/preprocessed/oulad_week4.csv	27.528	29	3,70
data/preprocessed/oulad_week8.csv	26.516	29	3,63
data/preprocessed/oulad_week12.csv	25.722	29	3,65
data/preprocessed/oulad_week16.csv	24.932	29	3,52
data/preprocessed/oulad_week24.csv	23.562	29	3,38

Các tập dữ liệu theo mốc dự đoán là đầu ra của giai đoạn tiền xử lý. Giai đoạn mô hình hóa tiếp theo bao gồm xây dựng phương án chia tập kiểm soát sự trùng lặp sinh viên giữa các tập, mã hóa và chuẩn hóa dựa trên tập huấn luyện, lựa chọn đặc trưng và huấn luyện mô hình dự đoán.

Kết luận tiến độ và kế hoạch tuần tiếp theo

Kết quả thực hiện. Trên cơ sở bản tiền xử lý thử nghiệm của tuần 2, dữ liệu OULAD đã được khảo sát lại có hệ thống, bổ sung đánh giá chất lượng và hoàn thiện quy trình tích hợp tại năm mốc dự đoán (tuần 4, 8, 12, 16 và 24). Mỗi tập dữ liệu có 23 đặc trưng ứng viên, tách riêng với nhãn mục tiêu và các trường định danh.

Giới hạn dữ liệu. OULAD không cung cấp thời điểm công bố điểm hoặc lịch sử cập nhật thuộc tính nền; vì vậy, `score` không được sử dụng làm đặc trưng cảnh báo sớm. Những trường hợp trùng lặp chưa xác nhận là lỗi được giữ nguyên; tập lượt học đủ điều kiện thay đổi theo từng mốc.

Công việc dự kiến trong tuần 4

Bảng 44: Các hạng mục công việc dự kiến trong tuần tiếp theo

STT	Hạng mục công việc	Kết quả cần đạt
1	Rà soát và điều chỉnh phương án chia dữ liệu	Kiểm tra lại cách chia theo sinh viên đã thử nghiệm ở tuần 2; áp dụng nhất quán cho năm mốc mới, đối chiếu giao thoa sinh viên và phân phối nhãn.
2	Điều chỉnh quy trình mã hóa và chuẩn hóa đầu vào	Kế thừa cách xử lý thiếu, One-Hot Encoding và chuẩn hóa đã thử nghiệm; cập nhật cho bộ 23 đặc trưng và chỉ ước lượng tham số trên tập huấn luyện.
3	Khảo sát và lựa chọn đặc trưng	Rà soát biến ít thông tin, tương quan giữa các đặc trưng số và nguy cơ rò rỉ; lập danh sách đặc trưng giữ lại hoặc loại bỏ.
4	Kiểm tra mất cân bằng nhãn và phương án xử lý	Thống kê phân phối bốn lớp trên từng tập và từng mốc; xác định có cần trọng số lớp hoặc phương pháp xử lý khác trên tập huấn luyện.

Còn tiếp trang sau

Tiếp Bảng 44

STT	Hạng mục công việc	Kết quả cần đạt
5	Hoàn thiện bộ dữ liệu và Pipeline cho mô hình hóa	Kiểm tra đầu ra sau biến đổi, lưu tập đặc trưng–nhãn tại năm mốc và quy trình xử lý có thể tái sử dụng.
6	Nghiên cứu và xây dựng bước đầu mô hình cơ sở	Tìm hiểu các thuật toán phân loại phù hợp, lựa chọn mô hình đối chứng và thiết lập mã huấn luyện thử; chưa yêu cầu kết quả đánh giá trên tập kiểm tra.

Tài liệu tham khảo

[1] Kuzilek, J., Hlosta, M., & Zdrahal, Z. (2017). Open University Learning Analytics dataset. *Scientific Data*, 4, 170171. DOI: `https://doi.org/10.1038/sdata.2017.171`.

Nguồn kết quả thực nghiệm: Các bảng thống kê và hình minh họa được kết xuất từ kết quả thực thi quy trình khám phá và tiền xử lý dữ liệu OULAD trong tệp mã nguồn `preprocess.ipynb` của dự án.

Phụ lục A. Cấu trúc và miền quan sát của bảy bảng dữ liệu

Phần này trình bày chi tiết tên trường, ý nghĩa, kiểu dữ liệu và miền giá trị quan sát trên bảy bảng OULAD. Tổng cộng có 43 trường dữ liệu khi tính riêng từng bảng; các trường trùng tên vẫn được tính theo bảng nguồn tương ứng.

Bảng 45: Cấu trúc bảng `courses`

Cột dữ liệu	Ý nghĩa / đơn vị	Kiểu dữ liệu (Pandas)	Miền quan sát (không tính thiếu)
`code_module`	Mã học phần	str	AAA; BBB; CCC; DDD; EEE; FFF; GGG
`code_presentation`	Mã đợt mở lớp	str	2013B; 2013J; 2014B; 2014J
`module_presentation_length`	Thời lượng đợt học (ngày)	int64	234; 240; 241; 261; 262; 268; 269

Bảng 46: Cấu trúc bảng `assessments`

Cột dữ liệu	Ý nghĩa / đơn vị	Kiểu dữ liệu (Pandas)	Miền quan sát (không tính thiếu)
`code_module`	Mã học phần	str	AAA; BBB; CCC; DDD; EEE; FFF; GGG
`code_presentation`	Mã đợt mở lớp	str	2013B; 2013J; 2014B; 2014J
`id_assessment`	Mã bài đánh giá	int64	[1752; 40088]
`assessment_type`	Loại bài đánh giá	str	CMA; Exam; TMA
`date`	Hạn đánh giá (ngày tương đối)	float64	[12,0; 261,0]
`weight`	Trọng số (%)	float64	0,0; 1,0; 2,0; 3,0; 4,0; 5,0; 6,0; 7,0; 7,5; 8,0; 9,0; 10,0; 12,5; 15,0; 16,0; 17,5; 18,0; 20,0; 22,0; 25,0; 28,0; 30,0; 35,0; 100,0

Bảng 47: Cấu trúc bảng `studentInfo`

Cột dữ liệu	Ý nghĩa / đơn vị	Kiểu dữ liệu (Pandas)	Miền quan sát (không tính thiếu)
`code_module`	Mã học phần	str	AAA; BBB; CCC; DDD; EEE; FFF; GGG
`code_presentation`	Mã đợt mở lớp	str	2013B; 2013J; 2014B; 2014J
`id_student`	Mã sinh viên	int64	[3733; 2716795]
`gender`	Giới tính	str	F; M
`region`	Vùng cư trú	str	East Anglian Region; East Midlands Region; Ireland; London Region; North Region; North Western Region; Scotland; South East Region; South Region; South West Region; Wales; West Midlands Region; Yorkshire Region
`highest_education`	Trình độ học vấn cao nhất	str	A Level or Equivalent; HE Qualification; Lower Than A Level; No Formal quals; Post Graduate Qualification
`imd_band`	Nhóm chỉ số thiếu thốn kinh tế xã hội	str	0-10%; 10-20; 20-30%; 30-40%; 40-50%; 50-60%; 60-70%; 70-80%; 80-90%; 90-100%

Còn tiếp trang sau

Tiếp Bảng 47

Cột dữ liệu	Ý nghĩa / đơn vị	Kiểu dữ liệu (Pandas)	Miền quan sát (không tính thiếu)
age_band	Nhóm tuổi	str	0-35; 35-55; 55≤
num_of_prev_attempts	Số lần học trước	int64	0; 1; 2; 3; 4; 5; 6
studied_credits	Số tín chỉ đang học	int64	[30; 655]
disability	Khai báo khuyết tật	str	N; Y
final_result	Kết quả học tập cuối kỳ	str	Distinction; Fail; Pass; Withdrawn

Bảng 48: Cấu trúc bảng studentRegistration

Cột dữ liệu	Ý nghĩa / đơn vị	Kiểu dữ liệu (Pandas)	Miền quan sát (không tính thiếu)
code_module	Mã học phần	str	AAA; BBB; CCC; DDD; EEE; FFF; GGG
code_presentation	Mã đợt mở lớp	str	2013B; 2013J; 2014B; 2014J
id_student	Mã sinh viên	int64	[3733; 2716795]
date_registration	Ngày đăng ký tương đối	float64	[−322,0; 167,0]
date_unregistration	Ngày rút học tương đối	float64	[−365,0; 444,0]

Bảng 49: Cấu trúc bảng studentAssessment

Cột dữ liệu	Ý nghĩa / đơn vị	Kiểu dữ liệu (Pandas)	Miền quan sát (không tính thiếu)
id_assessment	Mã bài đánh giá	int64	[1752; 37443]
id_student	Mã sinh viên	int64	[6516; 2698588]
date_submitted	Ngày nộp bài tương đối	int64	[−11; 608]
is_banked	Cờ chuyển điểm từ lần học trước	int64	0; 1
score	Điểm (0-−100)	float64	[0,0; 100,0]

Bảng 50: Cấu trúc bảng `vle`

Cột dữ liệu	Ý nghĩa / đơn vị	Kiểu dữ liệu (Pandas)	Miền quan sát (không tính thiếu)
`id_site`	Mã tài nguyên	int64	[526721; 1077905]
`code_module`	Mã học phần	str	AAA; BBB; CCC; DDD; EEE; FFF; GGG
`code_presentation`	Mã đợt mở lớp	str	2013B; 2013J; 2014B; 2014J
`activity_type`	Loại hoạt động VLE	str	dataplus; dualpane; externalquiz; folder; forumng; glossary; homepage; htmlactivity; oucollaborate; oucontent; ouelluminate; ouwiki; page; questionnaire; quiz; repeatactivity; resource; sharedsubpage; subpage; url
`week_from`	Tuần bắt đầu dự kiến	float64	[0,0; 29,0]
`week_to`	Tuần kết thúc dự kiến	float64	[0,0; 29,0]

Bảng 51: Cấu trúc bảng `studentVle`

Cột dữ liệu	Ý nghĩa / đơn vị	Kiểu dữ liệu (Pandas)	Miền quan sát (không tính thiếu)
`code_module`	Mã học phần	str	AAA; BBB; CCC; DDD; EEE; FFF; GGG
`code_presentation`	Mã đợt mở lớp	str	2013B; 2013J; 2014B; 2014J
`id_student`	Mã sinh viên	int64	[6516; 2698588]
`id_site`	Mã tài nguyên	int64	[526721; 1049562]
`date`	Ngày tương tác tương đối	int64	[−25; 269]
`sum_click`	Số click trong bản ghi	int64	[1; 6977]

Phụ lục B. Chi tiết chuyển đổi kiểu dữ liệu

Bảng 52: Kiểu dữ liệu trước và sau chuẩn hóa

Bảng dữ liệu	Cột dữ liệu	Kiểu dữ liệu trước	Kiểu dữ liệu sau	Số giá trị thiếu
courses	code_module	str	string	0
courses	code_presentation	str	string	0
courses	module_presentation_length	int64	Int64	0
assessments	code_module	str	string	0
assessments	code_presentation	str	string	0
assessments	id_assessment	int64	Int64	0
assessments	assessment_type	str	string	0
assessments	date	float64	Int64	11
assessments	weight	float64	float64	0
studentInfo	code_module	str	string	0
studentInfo	code_presentation	str	string	0
studentInfo	id_student	int64	Int64	0
studentInfo	gender	str	string	0
studentInfo	region	str	string	0
studentInfo	highest_education	str	string	0
studentInfo	imd_band	str	string	0
studentInfo	age_band	str	string	0
studentInfo	num_of_prev_attempts	int64	Int64	0
studentInfo	studied_credits	int64	Int64	0
studentInfo	disability	str	string	0
studentInfo	final_result	str	string	0
studentInfo	imd_band_missing	int8	Int64	0
studentRegistration	code_module	str	string	0
studentRegistration	code_presentation	str	string	0
studentRegistration	id_student	int64	Int64	0
studentRegistration	date_registration	float64	Int64	45
studentRegistration	date_unregistration	float64	Int64	22.521
studentAssessment	id_assessment	int64	Int64	0
studentAssessment	id_student	int64	Int64	0
studentAssessment	date_submitted	int64	Int64	0
studentAssessment	is_banked	int64	Int64	0
studentAssessment	score	float64	float64	173
vle	id_site	int64	Int64	0
vle	code_module	str	string	0
vle	code_presentation	str	string	0
vle	activity_type	str	string	0
vle	week_from	float64	Int64	5.243
vle	week_to	float64	Int64	5.243

Kiểu `Int64` được sử dụng đối với những trường số nguyên có thể chứa giá trị thiếu. Phép chuyển đổi kiểu chỉ tác động đến cách biểu diễn dữ liệu và không thực hiện chuẩn hóa thang đo.

Phụ lục C. Danh mục và ý nghĩa 23 đặc trưng ứng viên

Bảng 53: Danh mục 23 đặc trưng đầu vào ứng viên

Đặc trưng đầu vào (X)	Nguồn	Định nghĩa	Ý nghĩa giá trị thiếu
`gender`	`student_base`	Giới tính	Không chấp nhận NA
`region`	`student_base`	Vùng cư trú	Không chấp nhận NA
`highest_education`	`student_base`	Trình độ học vấn cao nhất	Không chấp nhận NA
`imd_band`	`student_base`	`Unknown` cho thiếu; nhóm IMD thống nhất hậu tố %	Không chấp nhận NA
`age_band`	`student_base`	Nhóm tuổi	Không chấp nhận NA
`num_of_prev_attempts`	`student_base`	Số lần học trước	Không chấp nhận NA
`studied_credits`	`student_base`	Số tín chỉ đang học	Không chấp nhận NA
`disability`	`student_base`	Khai báo khuyết tật	Không chấp nhận NA
`imd_band_missing`	`student_base`	Cờ thiếu IMD ban đầu; gán cố định, không học từ y	Không chấp nhận NA
`date_registration`	`student_base`	Ngày đăng ký đã biết và không sau cutoff	Không chấp nhận NA
`module_presentation_length`	`student_base`	Thời lượng dự kiến của đợt học	Không chấp nhận NA
`n_submissions`	`studentAssessment` + `assessments`	Số bài TMA/CMA không banked nộp trong $[0, t]$	Không chấp nhận NA
`n_submissions_with_due_date`	`studentAssessment` + `assessments`	Số bài nộp trên có hạn xác định và hạn $\leq$ cutoff	Không chấp nhận NA
`n_late_submissions`	`studentAssessment` + `assessments`	Số bài có ngày nộp $>$ hạn, trong nhóm có hạn đến cutoff	Không chấp nhận NA
`late_submission_rate`	`studentAssessment` + `assessments`	Số bài muộn / số bài có hạn đến cutoff; NA nếu mẫu số 0	Không có bài đủ điều kiện xét tỷ lệ
`total_clicks`	`studentVle` + `vle`	Tổng click ghi nhận trong $[0, t]$, giữ log trùng chưa xác minh	Không chấp nhận NA
`active_days`	`studentVle` + `vle`	Số ngày khác nhau có bản ghi VLE trong $[0, t]$	Không chấp nhận NA
`resource_types_used`	`studentVle` + `vle`	Số `activity_type` khác nhau đã có tương tác trong cửa sổ	Không chấp nhận NA
`avg_clicks_per_day`	`studentVle` + `vle`	`total_clicks` / (cutoff+1), gồm ngày không có log	Không chấp nhận NA

Còn tiếp trang sau

Tiếp Bảng 53

Đặc trưng đầu vào (X)	Nguồn	Định nghĩa	Ý nghĩa giá trị thiếu
clicks_oucontent	studentVle + vle	Tổng click của loại oucontent trong $[0, t]$	Không chấp nhận NA
clicks_forumng	studentVle + vle	Tổng click của loại forumng trong $[0, t]$	Không chấp nhận NA
clicks_quiz	studentVle + vle	Tổng click của loại quiz trong $[0, t]$	Không chấp nhận NA
clicks_resource	studentVle + vle	Tổng click của loại resource trong $[0, t]$	Không chấp nhận NA

Danh mục thể hiện các thuộc tính đầu vào X ở giai đoạn sau tích hợp. Việc lựa chọn đặc trưng theo tiêu chí học máy thuộc giai đoạn mô hình hóa sau khi chia tập dữ liệu.

Phụ lục D. Quy tắc kiểm tra miền và ngoại lệ theo đợt học

Bảng 54: Chi tiết 62 phép kiểm tra miền hợp lệ

Bảng dữ liệu	Cột dữ liệu	Quy tắc hợp lệ	Số lượt vi phạm
courses	code_module	Mã gồm 3 chữ hoa	0
courses	code_presentation	Mã năm 20xx và kỳ B/J	0
courses	module_presentation_length	Số ngày nguyên dương	0
assessments	code_module	Mã gồm 3 chữ hoa	0
assessments	code_presentation	Mã năm 20xx và kỳ B/J	0
assessments	id_assessment	ID nguyên dương	0
assessments	date	Số ngày tương đối là số nguyên (cho phép âm)	0
assessments	weight	Giá trị thuộc [0.100]	0
studentInfo	code_module	Mã gồm 3 chữ hoa	0
studentInfo	code_presentation	Mã năm 20xx và kỳ B/J	0
studentInfo	id_student	ID nguyên dương	0
studentInfo	num_of_prev_attempts	Số nguyên không âm	0
studentInfo	studied_credits	Số nguyên không âm	0
studentRegistration	code_module	Mã gồm 3 chữ hoa	0
studentRegistration	code_presentation	Mã năm 20xx và kỳ B/J	0
studentRegistration	id_student	ID nguyên dương	0
studentRegistration	date_registration	Số ngày tương đối là số nguyên (cho phép âm)	0

Còn tiếp trang sau

Tiếp Bảng 54

Bảng dữ liệu	Cột dữ liệu	Quy tắc hợp lệ	Số lượt vi phạm
studentRegistration	date_unregistration	Số ngày tương đối là số nguyên (cho phép âm)	0
studentAssessment	id_assessment	ID nguyên dương	0
studentAssessment	id_student	ID nguyên dương	0
studentAssessment	date_submitted	Số ngày tương đối là số nguyên (cho phép âm)	0
studentAssessment	score	Giá trị thuộc [0.100]	0
vle	id_site	ID nguyên dương	0
vle	code_module	Mã gồm 3 chữ hoa	0
vle	code_presentation	Mã năm 20xx và kỳ B/J	0
vle	week_from	Số tuần nguyên không âm	0
vle	week_to	Số tuần nguyên không âm	0
studentVle	code_module	Mã gồm 3 chữ hoa	0
studentVle	code_presentation	Mã năm 20xx và kỳ B/J	0
studentVle	id_student	ID nguyên dương	0
studentVle	id_site	ID nguyên dương	0
studentVle	date	Số ngày tương đối là số nguyên (cho phép âm)	0
studentVle	sum_click	Số nguyên không âm	0
studentInfo	final_result	Thuộc tập: Distinction, Fail, Pass, Withdrawn	0
studentInfo	gender	Thuộc tập: F, M	0
studentInfo	disability	Thuộc tập: N, Y	0
studentInfo	age_band	Thuộc tập: 0-35. 35-55. 55≤	0
studentInfo	highest_education	Thuộc tập: A Level or Equivalent, HE Qualification, Lower Than A Level, No Formal quals, Post Graduate Qualification	0
assessments	assessment_type	Thuộc tập: CMA, Exam, TMA	0
studentAssessment	is_banked	Thuộc tập: 0. 1	0
studentInfo	imd_band	Dải thập phân vị từ 0-10 đến 90-100; hậu tố % tùy cách ghi nguồn	0
courses	code_module	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
courses	code_presentation	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0

Còn tiếp trang sau

Tiếp Bảng 54

Bảng dữ liệu	Cột dữ liệu	Quy tắc hợp lệ	Số lượt vi phạm
assessments	code_module	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
assessments	code_presentation	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
assessments	assessment_type	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	code_module	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	code_presentation	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	gender	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	region	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	highest_education	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	imd_band	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	age_band	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	disability	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentInfo	final_result	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentRegistratior	code_module	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentRegistration	code_presentation	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
vle	code_module	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
vle	code_presentation	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
vle	activity_type	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentVle	code_module	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0
studentVle	code_presentation	Không rỗng / không có khoảng trắng ở đầu hoặc cuối	0

Trên tổng số 62 quy tắc kiểm tra miền hợp lệ, không phát hiện lượt vi phạm nào trong dữ liệu được khảo sát.

Bảng 55: Tổng trọng số bài đánh giá theo học phần, đợt và nhóm

Mã học phần	Mã đợt học	Nhóm đánh giá	Số bài đánh giá	Số trọng số không thiếu	Tổng trọng số (%)
AAA	2013J	Exam	1	1	100,00
AAA	2013J	Trong kỳ (TMA/CMA)	5	5	100,00
AAA	2014J	Exam	1	1	100,00
AAA	2014J	Trong kỳ (TMA/CMA)	5	5	100,00
BBB	2013B	Exam	1	1	100,00
BBB	2013B	Trong kỳ (TMA/CMA)	11	11	100,00
BBB	2013J	Exam	1	1	100,00
BBB	2013J	Trong kỳ (TMA/CMA)	11	11	100,00
BBB	2014B	Exam	1	1	100,00
BBB	2014B	Trong kỳ (TMA/CMA)	11	11	100,00
BBB	2014J	Exam	1	1	100,00
BBB	2014J	Trong kỳ (TMA/CMA)	5	5	100,00
CCC	2014B	Exam	2	2	200,00
CCC	2014B	Trong kỳ (TMA/CMA)	8	8	100,00
CCC	2014J	Exam	2	2	200,00
CCC	2014J	Trong kỳ (TMA/CMA)	8	8	100,00
DDD	2013B	Exam	1	1	100,00
DDD	2013B	Trong kỳ (TMA/CMA)	13	13	100,00
DDD	2013J	Exam	1	1	100,00
DDD	2013J	Trong kỳ (TMA/CMA)	6	6	100,00
DDD	2014B	Exam	1	1	100,00
DDD	2014B	Trong kỳ (TMA/CMA)	6	6	100,00
DDD	2014J	Exam	1	1	100,00
DDD	2014J	Trong kỳ (TMA/CMA)	6	6	100,00
EEE	2013J	Exam	1	1	100,00
EEE	2013J	Trong kỳ (TMA/CMA)	4	4	100,00
EEE	2014B	Exam	1	1	100,00
EEE	2014B	Trong kỳ (TMA/CMA)	4	4	100,00
EEE	2014J	Exam	1	1	100,00
EEE	2014J	Trong kỳ (TMA/CMA)	4	4	100,00
FFF	2013B	Exam	1	1	100,00
FFF	2013B	Trong kỳ (TMA/CMA)	12	12	100,00
FFF	2013J	Exam	1	1	100,00
FFF	2013J	Trong kỳ (TMA/CMA)	12	12	100,00
FFF	2014B	Exam	1	1	100,00
FFF	2014B	Trong kỳ (TMA/CMA)	12	12	100,00
FFF	2014J	Exam	1	1	100,00
FFF	2014J	Trong kỳ (TMA/CMA)	12	12	100,00
GGG	2013J	Exam	1	1	100,00
GGG	2013J	Trong kỳ (TMA/CMA)	9	9	0,00

Còn tiếp trang sau

Tiếp Bảng 55

Mã học phần	Mã đợt học	Nhóm đánh giá	Số bài đánh giá	Số trọng số không thiếu	Tổng trọng số (%)
GGG	2014B	Exam	1	1	100,00
GGG	2014B	Trong kỳ (TMA/CMA)	9	9	0,00
GGG	2014J	Exam	1	1	100,00
GGG	2014J	Trong kỳ (TMA/CMA)	9	9	0,00

Tổng trọng số chỉ được diễn giải trong cùng học phần, đợt học và nhóm đánh giá; không tự ép mọi nhóm về tổng 100%.